

**Федеральное государственное бюджетное образовательное учреждение высшего
образования «Московский государственный университет имени М.В.Ломоносова»
Казахстанский филиал
Направление 38.03.01 Экономика**

Касенова Асем Ардаккызы

**ПРОГНОЗИРОВАНИЕ РИСКОВ БАНКОВСКОГО КРЕДИТОВАНИЯ С
ИСПОЛЬЗОВАНИЕМ ТЕХНОЛОГИЙ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА**

Выпускная квалификационная работа

Научный руководитель:

к.э.н., к.ф.-м.н., к.ю.н., доцент
В. Н. Сидоренко

Допустить к защите:

заведующий кафедрой
А. В. Сидорович

(подпись зав кафедрой)

«_____» _____ 2025 г.

Астана, 2026

ОГЛАВЛЕНИЕ

ГЛАВА 1. АЛГОРИТМЫ МАШИННОГО И ГЛУБОКОГО ОБУЧЕНИЯ

В ЗАДАЧЕ О КРЕДИТНОМ СКОРИНГЕ	3
1.1. Предобработка данных кредитной истории клиентов банка	3
1.1.1. Метод главных компонент	5
1.1.2. Определение аномального клиента	8
1.1.3. Статистический тест Колмогорова-Смирнова	11
1.1.4. Сильная корреляция соседних признаков	16
1.2. Базовые алгоритмы оценки вероятности возврата кредита	20
1.2.1. Деревья решений	20
1.2.2. Случайный лес	22
1.2.3. Градиентный бустинг	23
1.2.4. Нейронные сети	25

ГЛАВА 2. ТЕСТИРОВАНИЕ АЛГОРИТМОВ МАШИННОГО И ГЛУБОКОГО ОБУЧЕНИЯ НА БОЛЬШИХ ДАННЫХ ПО КРЕДИТНОМУ СКОРИНГУ .

2.1. Подбор гиперпараметров для алгоритмов машинного обучения при оценке возврата кредита	28
2.1.1. Деревья решений	28
2.1.2. Случайный лес	32
2.1.3. Градиентный бустинг	34
2.1.4. Нейронная сеть	36
2.2. Ограничения и возможности моделей	38

ЗАКЛЮЧЕНИЕ	40
----------------------	----

СПИСОК ЛИТЕРАТУРЫ	42
-----------------------------	----

ПРИЛОЖЕНИЕ 1.

ПРИЛОЖЕНИЕ 2.

ПРИЛОЖЕНИЕ 3.

ГЛАВА 1. АЛГОРИТМЫ МАШИННОГО И ГЛУБОКОГО ОБУЧЕНИЯ В ЗАДАЧЕ О КРЕДИТНОМ СКОРИНГЕ

1.1. Предобработка данных кредитной истории клиентов банка

В данной работе используются обезличенные данные АО «Альфа-Банка»¹. Данные состоят из 12 файлов (`train_data_0.pq` – `train_data_11.pq`), содержащих информацию о платежах клиентов банка. В каждом из 12 файлов содержится информация о 250 000 клиентах. При этом один клиент может иметь несколько кредитов, и каждому такому клиенту соответствует персональный `id` (идентификационный номер). Отдельно имеется файл `train_target.csv`, который состоит из 3 млн строк, и каждая строка соответствует клиенту с меткой (флагом) равной 0 (отсутствие дефолта) или 1 (наличие дефолта). Задача предобработки данных состоит в структурировании исходной информации, т.е. формирование единого датасета, выделение важных признаков (колонок), выявление аномальных клиентов (определение аномальности будет приведено ниже), визуализация данных и тестирование моделей МО и ГО на этих данных. Программный код формирования единого датасета реализован в листинге 1 (см. Приложение 1).

Комментарий 1. Пояснение к листингу 1:

1. Строки 1–3. Импортируются необходимые библиотеки: `pandas` – для работы с табличными данными, `os` – для работы с файловой системой и `pyarrow.parquet` – для чтения файлов формата `parquet`.

2. Строка 4. Задается путь `path = "train_data"` к папке, в которой находятся исходные файлы формата `pq`.

3. Строки 5–12. Запускается цикл `for`, который перебирает все файлы в папке `train_data`. Формируется имя поочередного файла `train_data_i.pq`, создается объект `ParquetDataset` для текущего файла, из которого данные считываются в `DataFrame` (`df`). Затем выполняется агрегация данных по признаку `id`, вычисляются средние значения признаков, после чего данные сохраняются в соответствующий `csv` – файл в папку `train_data_csv_all`.

4. Строка 13. Выводится список файлов каталога `train_data` для проверки корректности формирования файлов.

5. Строки 14–20. Задается путь к папке с полученными `csv`-файлами `train_data_csv_all`. Создается пустой список `frames` для последующего хранения отдельных `DataFrame`. Затем запускается цикл по файлам в папке `train_data_csv_all`, который последовательно перебирает все файлы в формате `csv`. Результат сохраняется в `DataFrame` (`df`) и добавляется в список `frames`.

6. Строки 21–23. Все элементы списка `frames` объединяются в единый `DataFrame` `result` с помощью функции `pd.concat`. Полученный датасет сохраняется в файл

¹Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения 25.11.2025). Загл. с экрана.

l_data_csv_all.csv, после чего заново считывается в переменную df_all для последующего анализа.

После преобразования получился следующий датасет. В таблице 1 приводится фрагмент датасета:

Таблица 1 – Фрагмент преобразованного датасета, содержащий первых 5 клиентов

id	enc_paym_0	enc_paym_1	enc_paym_2	enc_paym_3	enc_paym_4	flag
1750000	0.17	0.17	0.17	0.33	0.67	0
1750001	0.00	0.75	0.75	0.75	0.75	0
1750002	0.39	0.33	0.72	0.67	1.17	0
1750003	0.18	0.23	0.41	0.50	0.55	0
1750004	0.60	0.60	0.60	0.60	1.20	0

Примечание: id – идентификатор заявки; enc_paym_0, ..., enc_paym_n – статусы ежемесячных платежей за последние n месяцев; flag – статус кредита (0=кредит полностью оплачен). Полный датасет состоит из 61 признака, включая дополнительные характеристики по кредитам.

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Комментарий 2. Пояснение к агрегированию клиентов в листинге 1:

Агрегация клиентов по идентификатору id в строке 11 необходима для определения итоговой метки (флага) каждого клиента, поскольку одному заемщику может соответствовать несколько кредитных договоров. Задача состоит в присвоении каждому кредиту одного заемщика единую итоговую метку. В данном исследовании в качестве общего значения для всех кредитов используется среднее исходных значений. Для понимания идеи приводится следующий пример в виде таблицы 2:

Таблица 2 – Дисциплина оплаты кредитов клиента (id = 1)

id	N	M1	M2	M3	M4	M5	M6	flag
1	1	1	0	1	1	0	1	0
1	2	0	1	0	1	1	2	
1	3	1	2	0	0	3	2	
		Среднее значение						
1		0.67	1	0.33	1	1.33	1.67	0

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

В данной таблице признаки означают следующее:

1. id – идентификационный номер клиента;
2. N – номер кредита;
3. M1,...,M6 – статусы погашения в течение 6 месяцев (0=платеж вовремя оплачен, 1=задержка платежа на 1 день, 2=задержка платежа на 2 дня, 3=задержка платежа на 3 дня);
4. flag – статус кредита (0=кредит полностью оплачен).

В таблице 2 на пересечении N=2 (второго кредита) и M2 (платеж во втором месяце) выделена цифра 1, означающая, что платеж по второму кредиту во втором месяце был оплачен с опозданием на 1 день.

Таким образом, данные трех строк, соответствующих трем кредитам клиента, в таблице 2 были усреднены и преобразованы в одну строку, которая содержит агрегированную информацию по клиенту с $id = 1$. В целом агрегировать клиентов можно не только по среднему значению, но и по моде или медиане. Однако в данной работе выбрано среднее значение, поскольку оно обладает важными статистическими свойствами, такими как несмещенность и состоятельность. После группирования данных был сформирован новый датасет, состоящий из 3 млн клиентов, каждому из которых соответствует одна итоговая метка. Получившийся датасет содержит 61 признак, из которых далее необходимо отобрать наиболее информативные, т.е. такие признаки, существенно влияющие на точность алгоритмов МО и ГО.

1.1.1. Метод главных компонент

Метод главных компонент (англ. principal component analysis, PCA) – метод сокращения размерности данных, позволяющий уменьшать количество признаков с сохранением основного объема исходной информации², на которых обучаются модели МО и ГО.

Как уже было отмечено выше, сформированный датасет содержит 61 признак (столбец). Задача состоит в том, чтобы найти такие признаки, с помощью которых модели МО и ГО показывали бы приемлемую точность. Следует отметить, что редукция признаков может снизить точность алгоритмов, поэтому необходимо внимательно контролировать процесс сокращения данных. В качестве тестового алгоритма был выбран алгоритм Random Forest (случайный лес), поскольку в статье С.В. Смирнова³ был проведен анализ предпочтения исследователей к алгоритмам МО, показавший, что наиболее популярным является случайный лес.

Из преобразованного датасета изначально выбираются только некатегориальные признаки и формируется новый датасет, содержащий 41 признак. Ниже приводится их описание:

1. `pre_pterm` – плановое количество дней с даты открытия кредита до даты его закрытия;
2. `pre_fterm` – фактическое количество дней с даты открытия кредита до даты его закрытия;
3. `pre_loans_next_pay_summ` – сумма следующего платежа по кредиту;
4. `pre_loans_outstanding` – оставшаяся невыплаченная сумма кредита;
5. `pre_loans_total_overdue` – текущая просроченная задолженность по кредиту;
6. `pre_loans_max_overdue_sum` – максимальная просроченная задолженность по кредиту за весь срок;

²PCA [Электронный ресурс] / Python-библиотека для машинного обучения. URL: <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html> (дата обращения: 25.11.2025). Загл. с экрана.

³Смирнов С. В. Методы машинного обучения в макроэкономическом прогнозировании: предварительные итоги // Вопросы экономики. 2025. № 10. С. 134. URL: <https://www.vopreco.ru/jour/article/view/5470> (дата обращения: 25.11.2025).

7. pre_loans_credit_cost_rate – полная стоимость кредита;
8. is_zero_loans5 – флаг: нет просрочек до 5 дней;
9. is_zero_loans530 – флаг: нет просрочек от 5 до 30 дней;
10. is_zero_loans3060 – флаг: нет просрочек от 30 до 60 дней;
11. is_zero_loans6090 – флаг: нет просрочек от 60 до 90 дней;
12. is_zero_loans90 – флаг: нет просрочек более чем на 90 дней;
13. pre_util – отношение оставшейся невыплаченной суммы кредита к кредитному лимиту;
14. pre_maxover2limit – отношение максимальной просроченной задолженности к кредитному лимиту;
15. is_zero_util – флаг: отношение оставшейся невыплаченной суммы кредита к кредитному лимиту равно 0;
16. is_zero_over2limit – флаг: отношение текущей просроченной задолженности к кредитному лимиту равно 0;
17. enc_paym_0, ..., enc_paym_n – статусы ежемесячных платежей за последние n месяцев.

Далее из этих 41 признака необходимо выбрать только такие, которые вносят наибольший вклад в информативность данных. В листинге 2 (см. Приложение 1) реализован метод главных компонент. На таком наборе данных алгоритм случайного леса показывает следующие метрики (см. Таблицу 3):

Таблица 3 – Метрики точности на 41 признаке

Алгоритм – Случайный лес						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Ассигураcy точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.98	1.00	0.99	724650
1	0.00	0.00	0.00			25350
Тестовая выборка						
0	1.00	0.97	0.98	0.97	0.68	241508
1	0.00	0.00	0.00			8493

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

В формуле (1) $\lambda_1^{(p)}, \dots, \lambda_{41}^{(p)}$ – это доли собственных чисел ковариационной матрицы, выраженные в процентах в порядке убывания. Начиная с $\lambda_{18}^{(p)}$ эта доля не превышает 0.2%. Это означает, что существует 24 компоненты, которые вносят незначительный вклад в информативность данных. Метод PCA не представляет возможности точно определять какие именно исходные признаки вносят существенный вклад в информативность данных, поэтому для дальнейшего анализа необходимо самостоятельно выбирать и удалять признаки с таким низким вкладом.

Были получены результаты PCA:

$$\begin{aligned}
 \lambda_1^{(p)} &= 22.3, \lambda_2^{(p)} = 20.3, \lambda_3^{(p)} = 17.6, \lambda_4^{(p)} = 10.8, \lambda_5^{(p)} = 9.5, \\
 \lambda_6^{(p)} &= 7.6, \lambda_7^{(p)} = 4.2, \lambda_8^{(p)} = 1.7, \lambda_9^{(p)} = 1.5, \lambda_{10}^{(p)} = 0.8, \\
 \lambda_{11}^{(p)} &= 0.6, \lambda_{12}^{(p)} = 0.5, \lambda_{13}^{(p)} = 0.4, \lambda_{14}^{(p)} = 0.3, \lambda_{15}^{(p)} = 0.3, \\
 \lambda_{16}^{(p)} &= 0.2, \lambda_{17}^{(p)} = 0.2, \lambda_{18}^{(p)} = 0.1, \lambda_{19}^{(p)} = 0.1, \lambda_{20}^{(p)} = 0.1, \\
 \lambda_{21}^{(p)} &= 0.1, \lambda_{22}^{(p)} = 0.1, \lambda_{23}^{(p)} = 0.1, \lambda_{24}^{(p)} = 0.1, \lambda_{25}^{(p)} = 0.1, \\
 \lambda_{26}^{(p)} &= 0.1, \lambda_{27}^{(p)} = 0.1, \lambda_{28}^{(p)} = 0.1, \lambda_{29}^{(p)} = 0.1, \lambda_{30}^{(p)} = 0.1, \\
 \lambda_{31}^{(p)} &= 0.0, \lambda_{32}^{(p)} = 0.0, \lambda_{33}^{(p)} = 0.0, \lambda_{34}^{(p)} = 0.0, \lambda_{35}^{(p)} = 0.0, \\
 \lambda_{36}^{(p)} &= 0.0, \lambda_{37}^{(p)} = 0.0, \lambda_{38}^{(p)} = 0.0, \lambda_{39}^{(p)} = 0.0, \lambda_{40}^{(p)} = 0.0, \\
 \lambda_{41}^{(p)} &= 0.0
 \end{aligned} \tag{1}$$

Было сделано предположение, что наименее информативными признаками являются: `pre_pterm`, `pre_fterm`, `pre_loans_next_pay_summ`, `pre_loans_outstanding`, `pre_loans_total_overdue`, `pre_loans_max_overdue_sum`, `pre_loans_credit_cost_rate`, `is_zero_loans5`, `is_zero_loans530`, `is_zero_loans3060`, `is_zero_loans6090`, `is_zero_loans90`, `pre_util`, `pre_maxover2limit`, `is_zero_util`, `is_zero_over2limit`.

Для подтверждения необходимо повторно проделать метод PCA без 16 признаков, касательно которых было сделано предположение. В листинге 3 (см. Приложение 1) реализуется метод главных компонент.

Комментарий 3. Пояснение к листингу 3:

1. Строки 1–2. Задаётся файл с датасетом из 25 признаков, который считывается в объект `DataFrame(df_all_25)`.

2. Строки 3–11. Формируется список со статусами ежемесячных платежей `enc_paym_k`, $k = 0, \dots, 24$.

3. Строка 12. `X_pay_25 = df_all_25.loc[:, columns_pay].copy()` – из исходного датасета `df` выбираются 25 признаков, которые формируют матрицу `X_pay`, содержащую информацию о платёжной дисциплине.

4. Строка 13. Создаётся объект метода главных компонент PCA с параметрами по умолчанию.

5. Строка 14. На матрице `X_pay_25` обучается модель PCA.

6. Строка 15. Вычисляются доли объясненной дисперсии для каждого главного компонента.

Получается следующая значимость признаков, процентно выраженная в собственных числах ковариационной матрицы `X_pay`.

$$\begin{aligned}
 \lambda_1^{(p)} &= 66.3, \lambda_2^{(p)} = 15.6, \lambda_3^{(p)} = 5.5, \lambda_4^{(p)} = 2.9, \lambda_5^{(p)} = 1.8, \\
 \lambda_6^{(p)} &= 1.3, \lambda_7^{(p)} = 1.0, \lambda_8^{(p)} = 0.8, \lambda_9^{(p)} = 0.7, \lambda_{10}^{(p)} = 0.6, \\
 \lambda_{11}^{(p)} &= 0.5, \lambda_{12}^{(p)} = 0.4, \lambda_{13}^{(p)} = 0.4, \lambda_{14}^{(p)} = 0.3, \lambda_{15}^{(p)} = 0.3, \\
 \lambda_{16}^{(p)} &= 0.3, \lambda_{17}^{(p)} = 0.3, \lambda_{18}^{(p)} = 0.2, \lambda_{19}^{(p)} = 0.2, \lambda_{20}^{(p)} = 0.1, \\
 \lambda_{21}^{(p)} &= 0.1, \lambda_{22}^{(p)} = 0.1, \lambda_{23}^{(p)} = 0.1, \lambda_{24}^{(p)} = 0.1, \lambda_{25}^{(p)} = 0.1.
 \end{aligned} \tag{2}$$

Из формулы (2) можно заметить, что осталось только 25 признаков, где доли собственных чисел $\lambda_i^{(p)}$ близки к нулю, т.е. остались те признаки, которые вносят существенный вклад в информативность данных. Однако из таблицы 3 видно, что некоторые метрики для алгоритма случайного леса равны нулю, что является неприемлемым для прогнозирования кредитных рисков. Например, это метрики Recall и Precision, для дефолтных клиентов. Таким образом, метод PCA не оказал влияния на некоторые метрики алгоритма, поэтому требуется дальнейший детальный анализ данных (матрицы X_{raw}).

1.1.2. Определение аномального клиента

Рисунок 1 показывает, что доля недефолтных клиентов существенно велика и не соответствует статистике в реальной жизни. По данным Первого кредитного бюро Республики Казахстан около 20%⁴ казахстанских заемщиков имеют дефолтную кредитную историю, что подтверждает данное утверждение и указывает на наличие аномальности в классе недефолтных клиентов.




Рисунок 1 – Перекос в сторону недефолтных клиентов

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

В данной работе под аномальным клиентом понимается нетипичное поведение для большинства заемщиков. Речь идет о ситуации, когда клиент фактически не располагает достаточными денежными средствами для обслуживания кредита, однако продолжает вносить ежемесячные платежи с небольшими, но регулярными опозданиями, перезанимая необходимые суммы из других источников. В таблице 2 приведен пример неестественных выплат клиента, из которого видно, что платежная дисциплина клиента по отдельному кредиту не выглядит дефолтной, однако в среднем этот клиент не выплачивал обязательства пунктуально ни в один расчетный месяц (средние значения по месяцам представлены в последней строке таблицы). Ниже будет дано определение и алгоритм выявления таких клиентов в датасете.

⁴Можно ли «отбелить» кредитную историю и есть ли черный список должников в Казахстане [Электронный ресурс] / Информационный интернет-портал «Tengrinews». – URL: https://tengrinews.kz/kazakhstan_news/li-otb-elit-kreditnyyu-istoriyu-est-chernyy-spisok-doljnikov-560869/ (дата обращения: 25.11.2025). Загл. с экрана.

Определение 1. Аномальным клиентом является такой клиент, для которого выполняются два условия:

$$\begin{cases} (a) \text{ метка (флаг)} = 0, \\ (b) \min(\text{enc_paym_n}) > 0, \quad n = 0, \dots, 24. \end{cases} \quad (\text{anom})$$

В формуле (anom) условие (a) означает, что аномальный клиент в датасете является недефолтным, а условие (b) – по всем месяцам оплата кредитных обязательств проводилась с опозданием. В листинге 4 (см. Приложение 1) указана реализация формулы anom.

Комментарий 4. Пояснение к листингу 4:

1. Строка 1. Читаем файл train_target.csv с целевой переменной в датафрейме df_y.
 2. Строки 2–3. Из столбца flag датафрейма df_y извлекаются метки для первых 1000000 клиентов, где y – это исходные метки дефолта/недефолта, а y_ – новые метки, которые будут изменяться в процессе нахождения аномальных клиентов.
 3. Строка 4. Инициализируются счетчики counter_norm – число не аномальных клиентов, а counter_anom – число аномальных клиентов.
 4. Строка 5. Создаются пустые списки, в которые будут записываться индексы не аномальных (ind_norm) и аномальных клиентов (ind_anom).
 5. Строка 6. Запускается цикл по всем строкам матрицы X_pay_25, где i это порядковый номер клиента (индекс строки), а x_pay – массив платежной истории по всем месяцам.
 6. Строки 7–10. Проверяется условие, которое определяет изначально недефолтных клиентов ($y[i] == 0$), у которых по всем месяцам наблюдаются задержки платежей ($\min(x_pay) > 0$). Если оба условия для клиента выполняются, то счетчик аномальных клиентов увеличивается на 1 ($counter_anom += 1$) и пополняется список индексов аномальных клиентов ($ind_anom.append(i)$), а его новой метке $y[i]$ присваивается значение 1. Таким образом, часть клиентов, имевших исходную метку 0, переводится в класс аномальных клиентов с меткой 1.
 7. Строки 11–13. В случае неудовлетворения этим двум условиям цикл относит клиента к не аномальным ($counter_norm += 1$) и добавляет его индекс в список не аномальных клиентов (ind_norm).
 8. Строки 14–15. Выводится число аномальных и не аномальных клиентов.
- Данный алгоритм показал, что доля дефолтных клиентов увеличилась с 3.38% до 37.44% (см. Рисунок 2). Это означает, что часть недефолтных клиентов перешла в класс дефолтных, и именно они удовлетворяют определению (anom).




Рисунок 2 – Переход клиентов из класса «0» в класс «1»

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Для большей наглядности результат переклассификации представлен на диаграмме Эйлера-Венна (см. Рисунок 3), показывающий пересечение множеств клиентов с дефолтными и недефолтными метками. Красный круг соответствует всем клиентам с исходной недефолтной меткой (96.62%), зеленый круг – клиентам с дефолтной меткой (3.38%), а их пересечение отражает группу аномальных клиентов (34.06%).




Рисунок 3 – Пересечение дефолтных и недефолтных меток с выделением ошибочно недефолтных клиентов

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Далее необходимо посмотреть как отреагирует алгоритм случайного леса на данных преобразованиях согласно определению (anom). Под реакцией алгоритма понимается изменение точности метрик. После выявления аномальных клиентов качество модели значительно улучшилось (см. Таблицу 4).

Таблица 4 – Изменение точности метрик на признаках: enc_paym_0, ..., enc_paym_24.

Алгоритм – Случайный лес						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	0.99	0.97	0.98	0.99	1.00	469239
1	0.94	0.99	0.96			280761
Тестовая выборка						
0	0.99	0.97	0.98	0.98	0.98	156325
1	0.94	0.99	0.96			93676

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Если сравнить первоначальные результаты, то можно заметить, что если до этого модель игнорировала класс дефолтных клиентов (все метрики равнялись нулю, см. Таблицу 3), то после переклассификации метрики точности стали высокими: на обучающей выборке precision = 0.94, recall = 0.99, f1-score = 0.96, аналогичные значения показывает тестовая выборка. При этом качество предсказания недефолтного класса клиентов практически не ухудшилось, поскольку precision снизился с 1.00 до 0.99, а метрики recall и f1-score не изменились. Также ROC-AUC увеличился с 0.68 до 0.98, что свидетельствует о том, что теперь модель хорошо различает дефолтных и недефолтных клиентов. Одновременно увеличилось количество дефолтных клиентов в выборках за счет вновь выявленных аномальных наблюдений, что позволило алгоритму случайного леса показать эффективные результаты на обоих классах.

1.1.3. Статистический тест Колмогорова-Смирнова

Понятие аномального клиента, изложенное в разделе 1.1.2., основано на анализе платежного поведения заемщиков. Применение данного подхода привело к существенному улучшению метрик точности алгоритма случайного леса. Поэтому на следующем шаге проводится статистический анализ, позволяющий увидеть и обосновать, насколько поведение аномальных клиентов отличается от поведения дефолтных клиентов. Для проверки равенства (неравенства) функций распределения двух выборок применяется критерий Колмогорова⁵-Смирнова⁶.

Теорема 1 (Критерий однородности двух выборок Смирнова⁷). Пусть $F_{X_1}(x)$, $F_{X_2}(x)$ – выборочные функции распределения двух независимых выборок объемами n и m .

⁵Колмогоров А.Н. (1903-1987 гг.) – Герой Социалистического Труда, профессор Московского государственного университета, академик АН СССР – крупнейший математик XX века, является одним из основоположников современной теории вероятности.

⁶Смирнов Н.В. (1900-1966 гг.) – член-корреспондент АН СССР, один из создателей непараметрических методов математической статистики и теории предельных распределений порядковых статистик.

⁷Лемешко Б.Ю., Лемешко С.Б. О распределениях статистик и мощности критериев однородности двух выборок // Материалы Российской НТК “Информатика и проблемы коммуникаций”. 2005. Т. 1. С. 109. URL: https://ami.nstu.ru/~headrd/seminar/publik_html/popov_2005_1.pdf (дата обращения: 25.11.2025.)

Обозначим:

$$D_{n,m} = \sup_x |F_{X_1}(x) - F_{X_2}(x)|.$$

Тогда для любого $t > 0$ выполняется:

$$\forall t > 0 : \lim_{n,m \rightarrow \infty} P\left(\sqrt{\frac{nm}{n+m}} D_{n,m} \leq t\right) = K(t) = \sum_{j=-\infty}^{+\infty} (-1)^j e^{-2j^2 t^2}. \quad (3)$$

На основе статистики $D_{n,m}$ строится статистика критерия

$$t_{n,m} = \sqrt{\frac{nm}{n+m}} D_{n,m}.$$

В теореме 1 функция $K(t)$ называется функцией распределения Колмогорова.

С помощью этой статистики проверяются нулевая и альтернативная гипотезы о совпадении распределений двух выборок:

$$\begin{cases} \mathcal{H}_0 : F_{X_1}(x) = F_{X_2}(x), \\ \mathcal{H}_1 : F_{X_1}(x) \neq F_{X_2}(x). \end{cases}$$

При заданном уровне значимости α выбирается критическое значение K_α распределения Колмогорова. Правило принятия решения имеет следующий вид:

$$\begin{cases} t_{n,m} \leq K_\alpha, & \text{нулевая гипотеза } \mathcal{H}_0 \text{ не отвергается,} \\ t_{n,m} > K_\alpha, & \text{нулевая гипотеза } \mathcal{H}_0 \text{ отвергается в пользу } \mathcal{H}_1. \end{cases}$$

Для применения критерия Колмогорова-Смирнова клиенты были разделены на две подвыборки:

$$\begin{cases} X_1 := X_{1 \rightarrow 1}, (\text{default}), \\ X_2 := X_{0 \rightarrow 1}, (\text{anom}), \end{cases}$$

где X_1 – выборка клиентов, являющихся дефолтными до и после условия аномальности; X_2 – выборка клиентов, у которых метка изменилась с «0» на «1».

Задача состоит в том, чтобы выяснить, принадлежат ли выборки X_1 и X_2 одному распределению, применив критерий Колмогорова-Смирнова. Если выборки X_1 и X_2 принадлежат одному распределению (принятие гипотезы $\mathcal{H}_0$), то платежная дисциплина дефолтных и аномальных клиентов одинакова. Критерий Колмогорова-Смирнова реализуется в листинге 5 (см. Приложение 1).

Комментарий 5. Пояснение к листингу 5:

1. Строки 1–2. Выбирается признак за 14 месяц `enc_raum_14` и соответствующий столбец из `X_rau_25` сохраняется в переменную `T`.

2. Строка 3. Формируются три выборки по этому признаку: `x00` – клиенты с меткой «0» до и после выявления аномальных клиентов; `x01` – аномальные клиенты, у которых изменилась метка с «0» на «1» после выявления аномальности; `x11` – клиенты с меткой «1» до и после выявления аномальных клиентов.

3. Строки 4–7. Происходит фильтрация выборок `x00`, `x01`, `x11`, у которых отбрасываются наблюдения с платежными статусами 0, 1, 2, 3, 4, 5, поскольку агрегация

данных была произведена по среднему значению.

4. Строка 8. Определяется функция tu_cdf по двум выборкам $x1$ и $x2$, где параметр $step$ – шаг значения признака при построении функций распределения.

5. Строка 9. Выбирается максимальное значение (опоздание) из этих двух выборок.

6. Строка 10. Создаются пустые списки $F1$ и $F2$, в которые будут записываться значения.

7. Строка 11. Определяется длина выборок $x1$ и $x2$, состоящих из положительных значений.

8. Строки 12–14. В цикле для каждой точки tm с шагом 0.01 считается сколько наблюдений для выборок $x1$ и $x2$ попадают в интервал $(0; t)$.

9. Строки 15–17. Вычисляется вероятность каждой точки и получаются значения функции распределения (CDF). Далее считается статистика Колмогорова по формуле: $\sup_x |F_{X_1}(x) - F_{X_2}(x)| \sqrt{\frac{nm}{n+m}}$. Затем возвращаются рассчитанные значения $F1$, $F2$, K , tm .

10. Строки 18–21. Задается шаг $step = 0.01$ и вычисляются значения функции распределения CDF для пары «аномальных и дефолтных», а затем для «аномальных и недефолтных» клиентов.

Датасет содержит 25 дисциплинарных признаков ($enc_raum_0, \dots, enc_raum_24$), и для каждого из них необходимо применить данный тест, чтобы выяснить, для каких признаков принимается та или иная гипотеза. Поскольку в датасете 3 000 000 наблюдений (объемы выборок n и m велики), то при уровне значимости $\alpha = 0.05$ в качестве критического значения используется $K_\alpha = 1.36$.




Рисунок 4 – Функции распределения и функции плотностей распределения дефолтных и аномальных клиентов за 15 месяц

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Анализ показал, что первые 15 месяцев ($enc_raum_0, \dots, enc_raum_14$) поведение аномальных клиентов отличается от поведения дефолтных, а начиная с 16 по 25 месяц ($enc_raum_15, \dots, enc_raum_24$), поведение становится схожим. Так, например, для 15 месяца (enc_raum_14) (см. Рисунок 4) расчетное значение статистики $t_{n,m} = 1.41$.

Поскольку $K_\alpha = 1.36$ и $t_{n,m} > K_\alpha$, принимается гипотеза $\mathcal{H}_1$. Это означает, что финансовое поведение аномальных клиентов в 15 расчетном месяце, ранее относившихся к классу «0», отличается от поведения дефолтных клиентов. Для 16 месяца (епс_раут_15) (см. Рисунок 5) значение $t_{n,m} = 1.31$. В этом случае $t_{n,m} < K_\alpha$, поэтому принимается гипотеза $\mathcal{H}_0$. Функции распределений значений признака для аномальных и дефолтных клиентов не различаются.




Рисунок 5 – Функции распределения и функции плотностей распределения дефолтных и аномальных клиентов за 16 месяц

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Таким образом, поведение аномальных и дефолтных клиентов до 15 месяца различно, а начиная с 16 месяца их поведение становится схожим. Возникает следующий вопрос, если поведение аномальных клиентов отличается от поведения дефолтных (епс_раут_0, ..., епс_раут_15), то не является ли оно более близким к поведению недефолтных клиентов?




Рисунок 6 – Функции распределения и функции плотностей распределения недефолтных и аномальных клиентов за 15 месяц

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

При сравнении аномальных и недефолтных клиентов анализ показал, что за 15 месяц (см. Рисунок 6) их выплаты также существенно различались, поскольку при значении

статистики $t_{n,m} = 70.92$ и условия $t_{n,m} > K_\alpha$ принимается гипотеза $\mathcal{H}_1$, что свидетельствует об их абсолютном различии по поведению. Если сравнить поведение аномальных и недефолтных клиентов за 16 месяц (см. Рисунок 7), то также наблюдается существенное различие. Расчетное значение статистики $t_{n,m} = 68.6$ и поскольку $t_{n,m} > K_\alpha$, принимается гипотеза $\mathcal{H}_1$.




Рисунок 7 – Функции распределения и функции плотностей распределения недефолтных и аномальных клиентов за 16 месяц

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

В результате анализа при сравнении аномальных и дефолтных клиентов была выявлена их схожесть после 16 месяца, тогда как при сравнении аномальных и недефолтных за весь рассматриваемый период наблюдается устойчивое расхождение. Для наглядности результаты сведены в таблицу 5.

Из результатов применения критерия Колмогорова-Смирнова (см. Таблицу 5) видно, что все значения статистики $t_{n,m}$ при сравнении функций распределений $F_{X_{0 \rightarrow 1}}(x)$ и $F_{X_{1 \rightarrow 1}}(x)$ меньше, чем при сравнении $F_{X_{0 \rightarrow 1}}(x)$ и $F_{X_{0 \rightarrow 0}}(x)$. Отсюда следует, что аномальные клиенты по своему платежному поведению ближе к классу дефолтных заемщиков, чем к недефолтным.

Замечание 1 (К таблице 5). В таблице 5 все статистики $t_{n,m}$ для выборок $X_{0 \rightarrow 1}$ и $X_{1 \rightarrow 1}$ меньше, чем все статистики $t_{n,m}$ для выборок $X_{0 \rightarrow 1}$ и $X_{0 \rightarrow 0}$. Несмотря на то, что гипотеза $\mathcal{H}_0$ в первом случае не во всех месяцах принимается, выборки $X_{0 \rightarrow 1}$ и $X_{1 \rightarrow 1}$ более однородны, чем выборки $X_{0 \rightarrow 1}$ и $X_{0 \rightarrow 0}$.

Таблица 5 – Результаты критерия Колмогорова–Смирнова за 25 месяцев

Месяц	Аномальные и дефолтные клиенты		Аномальные и недефолтные клиенты	
	Статистика	Принятие гипотезы	Статистика	Принятие гипотезы
enc_paym_0	$t_{n,m} = 1.65, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 61.40, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_1	$t_{n,m} = 2.49, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 72.44, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_2	$t_{n,m} = 3.09, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 62.21, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_3	$t_{n,m} = 3.33, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 62.03, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_4	$t_{n,m} = 3.29, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 63.85, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_5	$t_{n,m} = 3.20, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 65.22, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_6	$t_{n,m} = 2.88, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 67.04, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_7	$t_{n,m} = 2.50, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 61.43, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_8	$t_{n,m} = 2.28, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 56.28, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_9	$t_{n,m} = 2.00, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 60.88, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_10	$t_{n,m} = 1.90, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 68.11, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_11	$t_{n,m} = 1.85, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 71.93, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_12	$t_{n,m} = 1.72, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 74.84, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_13	$t_{n,m} = 1.53, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 73.55, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_14	$t_{n,m} = 1.41, t_{n,m} > K_\alpha$	$\mathcal{H}_1$	$t_{n,m} = 70.92, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_15	$t_{n,m} = 1.31, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 68.86, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_16	$t_{n,m} = 1.17, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 68.26, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_17	$t_{n,m} = 1.03, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 67.03, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_18	$t_{n,m} = 0.99, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 65.48, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_19	$t_{n,m} = 0.84, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 64.54, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_20	$t_{n,m} = 0.79, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 62.74, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_21	$t_{n,m} = 0.80, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 60.50, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_22	$t_{n,m} = 0.80, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 58.80, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_23	$t_{n,m} = 0.80, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 57.53, t_{n,m} > K_\alpha$	$\mathcal{H}_1$
enc_paym_24	$t_{n,m} = 0.68, t_{n,m} < K_\alpha$	$\mathcal{H}_0$	$t_{n,m} = 53.10, t_{n,m} > K_\alpha$	$\mathcal{H}_1$

Примечание: $K_\alpha = 1.36$ при уровне значимости $\alpha = 0.05$.

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Результаты критерия Колмогорова-Смирнова показали, что распределения платежной дисциплины дефолтных и аномальных клиентов мало отличаются между собой, чем распределения недефолтных и аномальных клиентов. Следовательно, класс аномальных заемщиков необходимо выделить в отдельную группу.

1.1.4. Сильная корреляция соседних признаков

Для последующей редукции признакового пространства и улучшения метрик алгоритмов была проанализирована корреляция Пирсона⁸ соседних признаков enc_paym_0, ..., enc_paym_24. На практике некоторые признаки могут дублировать друг друга (явление мультиколлинеарности) и следовательно из пары сильно коррелирующих признаков необходимо оставить только один признак. В работе были выделены три группы клиентов:

⁸Пирсон К. (1857-1936 гг.) – британский математик, один из основоположников математической статистики.

недефолтные (0), дефолтные (1) и аномальные (0 → 1). Для детального анализа построен график (см. Рисунок 8), на котором представлены четыре коэффициента корреляции:

1. `corr_all` – общий коэффициент корреляции;
2. `corr_noddefault` – коэффициент корреляции для недефолтных клиентов;
3. `corr_default` – коэффициент корреляции для дефолтных клиентов;
4. `corr_anom` – коэффициент корреляции для аномальных клиентов.

Реализация кода для выявления сильно коррелирующих признаков представлена в листинге 6 (см. Приложение 1).

Комментарий 6. Пояснение к листингу 6:

1. Строки 1–2. Из датафрейма `X_pay_25` выбираются признаки платежной дисциплины `enc_paym_24` и `enc_paym_23`.

2. Строки 3–4. Создаются пустые списки для сохранения коэффициентов корреляции по всей совокупности клиентов `all_c`, недефолтным `nod_c`, дефолтным `def_c`, аномальным `ano_c`, а также номер месяца `month`.

3. Строка 5. Запускается цикл по признакам платежной дисциплины, начиная со 2 столбца, чтобы сравнивать текущий месяц с предыдущим.

4. Строки 6–17. Вычисляется коэффициент корреляции Пирсона для каждой из четырех групп и значения сохраняются в соответствующие списки `all_c`, `nod_c`, `def_c`, `ano_c`. Соответствующему коэффициенту корреляции номер месяца записывается в список `month`.

5. Строки 18–26. Создается график с заданными размерами, строятся линии коэффициентов корреляции для каждой из четырех групп, указываются названия осей, где ось `X` – номер месяца, а ось `Y` – коэффициент корреляции.

На рисунке 8 видно, что платежная дисциплина аномальных и дефолтных клиентов схожа друг с другом в отличие от аномальных и недефолтных клиентов.




Рисунок 8 – Изменение корреляции между соседними признаками

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

В таблице 6 указаны значения коэффициентов корреляции и теста Фишера⁹ на равенство выборочного коэффициента корреляции (r) некоторому теоретическому коэффициенту корреляции (R) всех значений соседних признаков. Фишер показал, что статистика (z -преобразование Фишера)^{10,11}:

$$z(r) = \frac{1}{2} \ln \frac{1+r}{1-r} \quad (Fisher)$$

имеет приближенно нормальное распределение

$$z(r) \sim N\left(\frac{1}{2} \ln \frac{1+R}{1-R}, \frac{1}{n-3}\right),$$

где R – некоторый теоретический коэффициент корреляции, n – объем выборки, r – выборочный коэффициент корреляции.

В качестве теоретического коэффициента корреляции (R) в исследовании используется коэффициент корреляции всей совокупности клиентов для соответствующих значений соседних признаков. Для каждой из трех групп (недефолтных, дефолтных и аномальных клиентов) вычисляется свой выборочный коэффициент корреляции (r). Далее проверяется гипотеза о равенстве корреляций выборочной и генеральной совокупностей:

$$\begin{cases} \mathcal{H}_0 : r = R, \\ \mathcal{H}_1 : r \neq R. \end{cases}$$

В качестве статистики критерия Фишера используется величина

$$t = \frac{z(r) - z(R)}{\sqrt{\frac{1}{n-3}}}$$

При заданном уровне значимости α гипотеза принимается (отвергается) в случаях:

$$\begin{cases} |t| \leq t_{crit}, & \text{нулевая гипотеза } H_0 \text{ не отвергается,} \\ |t| > t_{crit}, & \text{нулевая гипотеза } H_0 \text{ отвергается в пользу } H_1. \end{cases}$$

Если посмотреть на эти значения статистик в разрезе для каждой группы (см. Таблицу 6), то можно заметить, что начиная со сравнения 16 и 17 месяцев (см. Листинг 7) (см. Приложение 1), коэффициент корреляции одной из трех групп принимает гипотезу $\mathcal{H}_0: |t| < t_{crit}$. Такая тенденция прослеживается до сравнения 20 и 21 месяца.

⁹Фишер Р.Э. (1890-1962 гг.) – британский статистик, один из основателей математической статистики и математической популяционной генетики.

¹⁰Fisher R.A. Frequency Distribution of the Values of the Correlation Coefficient in Samples from an Indefinitely Large Population // *Biometrika*. 1915. №4(10). P. 507. URL: <https://www2.stat.duke.edu/courses/Spring05/sta215/lec/Fish1915.pdf> (дата обращения: 25.11.2025).

¹¹Лемешко Б.Ю., Танасейчук А.В. Исследование распределения оценок коэффициента корреляции в зависимости от истинного значения корреляции // Материалы VIII международной конференции “Актуальные проблемы электронного приборостроения”. 2006. Т. 6. С. 91. http://www.ami.nstu.ru/~headrd/seminar/publik_html/APEP2006_4.htm (дата обращения: 25.11.2025).

Таблица 6 – Результаты теста Фишера за 25 месяцев

Месяц	Недефолтные клиенты		Дефолтные клиенты		Аномальные клиенты		Все клиенты
	Статистика	Гипотеза	Статистика	Гипотеза	Статистика	Гипотеза	Корреляция Пирсона
enc_paym_0 enc_paym_1	$t_{nod} = 505.11$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 195.08$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 238.49$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.63$
enc_paym_1 enc_paym_2	$t_{nod} = 188.29$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 161.96$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 189.95$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.80$
enc_paym_2 enc_paym_3	$t_{nod} = 132.87$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 160.51$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 183.05$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.85$
enc_paym_3 enc_paym_4	$t_{nod} = 95.71$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 133.53$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 147.53$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.87$
enc_paym_4 enc_paym_5	$t_{nod} = 74.37$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 120.26$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 136.01$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.89$
enc_paym_5 enc_paym_6	$t_{nod} = 50.52$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 76.73$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 84.20$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.88$
enc_paym_6 enc_paym_7	$t_{nod} = 40.55$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 66.10$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 75.36$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.91$
enc_paym_7 enc_paym_8	$t_{nod} = 34.57$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 61.13$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 71.94$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.92$
enc_paym_8 enc_paym_9	$t_{nod} = 30.71$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 58.64$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 64.91$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.93$
enc_paym_9 enc_paym_10	$t_{nod} = 21.29$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 36.56$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 37.83$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.92$
enc_paym_10 enc_paym_11	$t_{nod} = 16.36$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 26.75$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 31.11$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.93$
enc_paym_11 enc_paym_12	$t_{nod} = 11.00$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 14.11$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 15.34$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.91$
enc_paym_12 enc_paym_13	$t_{nod} = 4.13$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 3.23$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 4.54$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.93$
enc_paym_13 enc_paym_14	$t_{nod} = 6.38$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 4.42$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 14.78$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.96$
enc_paym_14 enc_paym_15	$t_{nod} = 8.39$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 11.74$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 21.25$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.96$
enc_paym_15 enc_paym_16	$t_{nod} = 2.57$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 3.57$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 6.86$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.97$
enc_paym_16 enc_paym_17	$t_{nod} = 4.14$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 1.89$ $ t_{def} \leq t_{crit}$	$\mathcal{H}_0$	$t_{ano} = 11.66$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.97$
enc_paym_17 enc_paym_18	$t_{nod} = 1.68$ $ t_{nod} \leq t_{crit}$	$\mathcal{H}_0$	$t_{def} = 13.57$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 5.95$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.97$
enc_paym_18 enc_paym_19	$t_{nod} = 1.12$ $ t_{nod} \leq t_{crit}$	$\mathcal{H}_0$	$t_{def} = 11.44$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 7.87$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.97$
enc_paym_19 enc_paym_20	$t_{nod} = 0.71$ $ t_{nod} \leq t_{crit}$	$\mathcal{H}_0$	$t_{def} = 9.48$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 1.87$ $ t_{ano} \leq t_{crit}$	$\mathcal{H}_0$	$r_{all} = 0.97$
enc_paym_20 enc_paym_21	$t_{nod} = 0.64$ $ t_{nod} \leq t_{crit}$	$\mathcal{H}_0$	$t_{def} = 5.11$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 3.21$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.97$
enc_paym_21 enc_paym_22	$t_{nod} = 2.86$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 14.00$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 5.77$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.97$
enc_paym_22 enc_paym_23	$t_{nod} = 3.48$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 15.23$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 13.21$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.97$
enc_paym_23 enc_paym_24	$t_{nod} = 22.36$ $ t_{nod} > t_{crit}$	$\mathcal{H}_1$	$t_{def} = 69.20$ $ t_{def} > t_{crit}$	$\mathcal{H}_1$	$t_{ano} = 66.41$ $ t_{ano} > t_{crit}$	$\mathcal{H}_1$	$r_{all} = 0.79$

Примечание: $t_{crit} = 1.96$ при уровне значимости $\alpha = 0.05$.Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Поскольку финансовая дисциплина в соседних месяцах схожа друг с другом, то принимается решение об исключении сильно коррелирующих признаков. В таком случае исключаются шесть признаков: `enc_paym_16`, ..., `enc_paym_21`.

1.2. Базовые алгоритмы оценки вероятности возврата кредита

1.2.1. Деревья решений

Необходимо протестировать предобработанные данные на таких базовых алгоритмах, как деревья решений (Decision Tree), случайный лес (Random Forest), градиентный бустинг (Gradient Boosting) и нейронные сети (Neural Networks). Важно отметить, что алгоритмы тестируются на 1 000 000 данных и полученные метрики точности будут сравниваться с метриками, которые будут получены после тестирования на больших данных (3 000 000 клиентов). Тестирование на небольших данных проводится с целью экономии объема оперативной памяти компьютера.

Результаты метрик точности позволяют понять насколько хорошо модель справляется с задачей классификации. Для этого необходимо выявить одно из двух явлений МО и ГО: переобучение или недообучение. Переобучение – явление, когда алгоритм хорошо распознает объекты из обучающей (тренировочной) выборки, но хуже их классифицирует на тестовой выборке. Модель стремится запомнить всевозможные примеры из обучающих данных, вместо того, чтобы научиться выявлять особенности. Недообучение – явление, при котором простая модель не успевает уловить сложные закономерности между признаками и меткой дефолта. В этом случае алгоритм показывает низкие метрики на обучающей и тестовой выборках, т.е. модель плохо разделяет надежных и рискованных клиентов даже на тех данных, на которых она обучалась.

Деревья решений (Decision Tree) – это один из алгоритмов МО, который по шагам делит заемщиков на группы с помощью последовательных вопросов вида «да» или «нет»¹². На каждом шаге выбирается такой признак, который сильнее влияет на результат, а в конечных вершинах алгоритм выдает прогноз вероятности дефолта клиента. Алгоритм решающих деревьев представлен в листинге 8 (см. Приложение 2).

Результаты алгоритма решающих деревьев (см. Таблицу 7) демонстрируют высокую точность. Видно, что метрики класса «0» на тренировочной выборке: `precision` = 1.00, `recall` = 0.99, `f1-score` = 0.99 выше в отличие от тестовой выборки, где `precision` = 0.98, `recall` = 0.97, `f1-score` = 0.97. Это означает, что алгоритм лучше распознает недефолтных клиентов на тренировочных данных, чем на тестовых. Аналогичная ситуация наблюдается у класса «1», где на тренировочных данных метрики выше, чем на тестовых. При этом результаты на двух выборках ниже, чем у «0» класса, что указывает на то, что дефолтные клиенты хуже

¹²Wang H. Application of Decision Tree Model in Personal Credit Scoring and Its Fairness Optimization // *Advances in Economics, Management and Political Sciences*. 2025. P. 109. URL: https://www.researchgate.net/publication/390979182_Application_of_Decision_Tree_Model_in_Personal_Credit_Scoring_and_Its_Fairness_Optimization (дата обращения: 25.11.2025).

распознаются.

Таблица 7 – Метрики точности алгоритма Decision Tree на 1 000 000 данных

Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Assuracы точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.99	0.99	0.99	0.99	469239
1	0.98	1.00	0.99			280761
Тестовая выборка						
0	0.98	0.97	0.97	0.97	0.97	156325
1	0.95	0.96	0.96			93676

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Также метрики ассурасу и ROC-AUC (см. Рисунок 9) выше на тренировочной выборке, чем на тестовой. Следовательно, можно сделать вывод о наличии переобучения алгоритма Decision Tree.




Рисунок 9 – Метрика ROC–AUC на тренировочных и тестовых данных алгоритма Decision Tree

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Для более подробной картины приведена матрица ошибок (см. Таблицу 10). На тренировочных данных верно классифицированы 469 203 недефолтных и 275 454 дефолтных клиентов. При этом 36 недефолтных клиентов ошибочно отнесены к дефолтным, и только 5 307 дефолтов алгоритм принял за недефолт.

На тестовой выборке алгоритм чаще ошибается. Верно распознаны 152 768 недефолтных и 89 202 дефолтных клиентов. Алгоритм ошибочно принял 3 557 недефолта за дефолт, и 4 474 дефолтов за недефолт. Таким образом, матрица ошибок указывает на ухудшение предсказаний решающих деревьев на тестовых данных, что подтверждает вывод о переобучении данного алгоритма.




Рисунок 10 – Матрица ошибок на тренировочных и тестовых данных алгоритма Decision Tree

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

1.2.2. Случайный лес

Случайный лес (Random Forest) – это алгоритм МО, состоящий из множества отдельных независимых деревьев решений. Каждое дерево выдает свое предсказание по возврату кредита, а затем итоговое предсказание определяется по принципу большинства. Данный алгоритм реализован в листинге 9 (см. Приложение 2).

Алгоритм случайного леса также показывает высокие результаты распознавания клиентов (см. Таблицу 8). Можно заметить, что метрики класса «0» recall и f1-score на тренировочных данных выше, чем на тестовых, а метрика precision остается на одинаково высоком уровне. Метрики класса «1» precision и f1-score также на тренировочной выборке выше, чем на тестовой.

Таблица 8 – Метрики точности алгоритма Random Forest на 1 000 000 данных

Flag метка	Precision точность	Recall полнота	f1-score f1-мера	Accuracy точность	ROC-AUC	Количество
Тренировочная выборка						
0	1.00	0.99	0.99	0.99	0.99	469239
1	0.98	1.00	0.99			280761
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	156325
1	0.95	1.00	0.97			93676

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Метрики accuracy и ROC-AUC (см. Рисунок 11) показывают небольшую разницу между тренировочными и тестовыми данными. Это также, как и в предыдущем алгоритме указывает на склонность случайного леса к переобучению.




Рисунок 11 – Метрика ROC–AUC на тренировочных и тестовых данных алгоритма Random Forest

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Если посмотреть в количественном разрезе (см. Рисунок 12), то на тренировочных данных алгоритм 469 166 недефолтных клиентов определяет верно, а 73 неверно относит к дефолтным. Также 275 470 дефолтов алгоритм правильно определяет, но 5 291 клиент неверно относит к недефолтным.

На тестовых данных случайный лес показывает хуже результат: 156 121 недефолтных клиентов правильно распознаются, а 204 неверно определяются как дефолтные. Также 89 066 дефолтов правильно классифицируются, однако 4 610 ошибочно относятся к недефолтным. Поэтому матрица ошибок также обосновывает склонность случайного леса к переобучению.




Рисунок 12 – Матрица ошибок на тренировочных и тестовых данных алгоритма Random Forest

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

1.2.3. Градиентный бустинг

Градиентный бустинг (Gradient Boosting) – комбинация множества простых алгоритмов деревьев решений, где каждый новый алгоритм исправляет ошибки предыдущего. Алгоритм градиентного бустинга реализован в листинге 10 (см. Приложение 2).

Все метрики точности данного алгоритма (см. Таблицу 9) обоих классов показывают высокие результаты, что делает данную модель почти идеальной. Небольшим недостатком является более низкая точность метрик класса «1» на обеих выборках, что свидетельствует о более высокой ошибочной вероятности предсказаний на дефолтных клиентах.

Таблица 9 – Метрики точности алгоритма Gradient Boosting на 1 000 000 данных

Flag метка	Precision точность	Recall полнота	f1-score f1-мера	Accuracy точность	ROC-AUC	Количество
Тренировочная выборка						
0	0.99	0.97	0.98	0.98	0.98	469239
1	0.95	0.99	0.97			280761
Тестовая выборка						
0	0.99	0.97	0.98	0.98	0.98	156325
1	0.95	0.99	0.97			93676

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Также это могут подтвердить метрики ассигасы и ROC-AUC (см. Рисунок 13), которые показывают идентичные результаты на обеих выборках. Это делает алгоритм градиентного бустинга наиболее предпочтительным в прогнозировании дефолта.




Рисунок 13 – Метрика ROC-AUC на тренировочных и тестовых данных алгоритма Gradient Boosting

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Матрица ошибок (см. Рисунок 14) показывает, что на тренировочных данных алгоритм правильно определяет 466 566 недефолтных клиентов, а 2 673 ошибочно относит к дефолтным. Верно классифицирует 267 366 дефолтных клиентов, а 13 395 неверно предсказывает как недефолтных. На тестовых данных неверно относит 912 недефолтных клиентов к дефолтным, а 4 557 дефолтных к недефолтным, что указывает на сбалансированность предсказаний алгоритма.




Рисунок 14 – Матрица ошибок на тренировочных данных алгоритма Gradient Boosting

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

1.2.4. Нейронные сети

Нейронные сети (Neural Networks) – математическая модель, позволяющая компьютерам имитировать работу человеческого мозга. Она состоит из множества простых узлов, которые образуют нейроны, сгруппированных в слои. Главными задачами нейронных сетей являются распознавание скрытых закономерностей в данных и делать прогноз. В данной работе используется нейронная сеть, состоящая из трех слоев (см. Рисунок 15):

1. входной слой – состоит из 19 нейронов (равен количеству дисциплинарных признаков: `enc_paym_0`, ..., `enc_paym_15`, `enc_paym_22`, ..., `enc_paym_24`);
2. скрытый слой – 32 нейрона;
3. выходной слой – 1 нейрон, который дает оценку вероятности (p) дефолта заемщика.

На вход передаются значения платежной дисциплины клиентов `enc_paym_0`, ..., `enc_paym_15`, `enc_paym_22`, ..., `enc_paym_24`. Далее 19 признаков поступают в скрытый слой, состоящий из 32 нейронов. Каждому признаку присваивается свой вес важности и вычисляется его взвешенная сумма. К полученной сумме применяется функция активации (в данной работе используется ReLu), которая «включает» нейрон, если суммарный сигнал превышает пороговое значение. В таком случае нейрон передает сигнал каждому связанному с ним нейроном в следующем слое. Если сумма ниже порогового значения, то нейрон «выключается» и данный признак является незначимым. В скрытом слое образуются 32 различные комбинации для 19 признаков и далее каждый из 32 нейронов выдает собственную оценку вероятности. В выходном слое из полученных 32 сигналов выбирается ответ с наибольшим весом. Таким образом, формируется ответ заемщику о выдаче или отказе в кредите. Алгоритм нейронной сети представлен в листинге 11 (см. Приложение 2).




Рисунок 15 – Структура нейронной сети для оценки вероятности дефолта заемщика

Источник: составлено автором на основе программы Lucidchart (дата обращения: 25.11.2025).

Результаты нейронной сети (см. Таблицу 10), как и градиентного бустинга показывает высокую точность распознавания клиентов, но также имеет выше вероятность ошибочного предсказания на дефолтных клиентах.

Таблица 10 – Метрики точности алгоритма Neural Network на 1 000 000 данных

Flag метка	Precision точность	Recall полнота	f1-score f1-мера	Accuracy точность	ROC-AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.99	0.98	0.98	469239
1	0.95	1.00	0.97			280761
Тестовая выборка						
0	1.00	0.97	0.99	0.98	0.97	156325
1	0.95	1.00	0.97			93676

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Метрики ассигасу и ROC-AUC демонстрируют одинаковую высокую точность, что также относит нейронные сети к наиболее предпочтительным алгоритмам для прогнозирования дефолта заемщиков (см. Рисунок 16).




Рисунок 16 – Метрика ROC–AUC на тренировочных и тестовых данных алгоритма Neural Network

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Матрицы ошибок на тренировочных и тестовых данных (см. Рисунок 17) показывают, что по сравнению с другими моделями, нейронные сети показывают меньше ошибочных предсказаний на тренировочной и тестовой выборке. Это указывает на то, что нейронные сети являются одним из лучших моделей для прогнозов.




Рисунок 17 – Матрица ошибок на тренировочных и тестовых данных алгоритма Neural Network

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

ГЛАВА 2. ТЕСТИРОВАНИЕ АЛГОРИТМОВ МАШИННОГО И ГЛУБОКОГО ОБУЧЕНИЯ НА БОЛЬШИХ ДАННЫХ ПО КРЕДИТНОМУ СКОРИНГУ

2.1. Подбор гиперпараметров для алгоритмов машинного обучения при оценке возврата кредита

В предыдущей главе было выяснено, что алгоритмы градиентного бустинга и нейронных сетей не имеют эффектов переобучения и недообучения. В случае градиентного бустинга используются гиперпараметры по умолчанию, результаты метрик которых не ниже метрик других алгоритмов. Это означает, что не требуется поиск гиперпараметров для данного алгоритма и можно остановиться на гиперпараметрах по умолчанию. Идентичная ситуация возникает у нейронной сети с отличием в том, что у нее метрики точности немного хуже, чем у алгоритма градиентного бустинга. В этой главе будут подобраны гиперпараметры для алгоритмов деревьев решений и случайного леса, поскольку они обладают эффектом переобучения. Основным инструментом для поиска оптимальных гиперпараметров используются классы из библиотеки `sklearn`: `GridSearchCV`¹³ и `RandomizedSearchCV`¹⁴.

Гиперпараметры – это такие параметры модели, которые задаются до начала работы модели. Правильно подобранные параметры позволяют улучшить качество предсказаний моделей. Каждому алгоритму МО присущи собственные наборы гиперпараметров, которые будут рассматриваться ниже. Существуют два метода подбора гиперпараметров:

1. `GridSearchCV` – метод подбора оптимальных гиперпараметров для модели с помощью перебора всех возможных комбинаций из заданного набора, что является ресурсозатратным способом.
2. `RandomizedSearchCV` – метод, позволяющий выбирать количество случайных комбинаций из заданного набора гиперпараметров. Является наиболее эффективным методом по времени при работе с большими данными.

2.1.1. Деревья решений

Для алгоритма классификации решающих деревьев (Decision Tree Classifier) основными гиперпараметрами являются:

1. `criterion` – критерий качества разбиения, определяющий показатель, по которому алгоритм лучше классифицирует клиентов.

¹³`GridSearchCV` [Электронный ресурс] / Python-библиотека для машинного обучения. URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html (дата обращения: 25.11.2025). Загл. с экрана.

¹⁴`RandomizedSearchCV` [Электронный ресурс] / Python-библиотека для машинного обучения. URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.RandomizedSearchCV.html (дата обращения: 25.11.2025). Загл. с экрана.

a) `gini` – индекс Джини¹⁵, измеряющий неоднородность двух классов (0 и 1) внутри узла. Если индекс равен 0, значит в узле содержатся объекты одного класса. Чем индекс ближе к 0, тем лучше алгоритм определяет класс клиента. Индекс Джини в алгоритме Decision Tree используется по умолчанию, поскольку быстрее вычисляется;

b) `entropy` – энтропия Шеннона¹⁶, измеряющий степень смешанности классов. Высокая энтропия свидетельствует о высокой неоднородности классов, чем ниже энтропия, тем узел более однородный. Алгоритм выбирает разбиения с наиболее низкой энтропией, т.е. содержатся большинство объектов одного класса;

c) `log_loss` – логарифмическая функция потерь. В данном случае алгоритм не просто выбирает класс, а оценивает их вероятности. За каждый неверный прогноз вводит штраф.

2. `max_depth` – максимальная глубина дерева решений. Чем больше глубина, тем длиннее цепочка вопросов, чтобы выдать прогноз по клиенту. При небольших значениях алгоритм делает мало разбиений и недообучается, т.е. плохо объясняет данные и дает невысокую точность на обучающей и тестовой выборках. При высоких значениях алгоритм, наоборот, переобучается, запоминает все особенности обучающей выборки, но плохо классифицирует клиентов на тестовых данных.

3. `min_samples_split` – параметр задает минимальное число наблюдений в узле, при котором возможно следующее разбиение на два дочерних. Если в узле наблюдений меньше заданного порога, то дальнейшее разбиение не выполняется, и узел становится конечным.

4. `min_samples_leaf` – параметр с минимальным заданным количеством наблюдений после разбиения в каждом узле, что позволяет дереву не создавать слишком маленькие группы клиентов и служит инструментом против переобучения алгоритма.

5. `max_features` – параметр задает случайное количество признаков, среди которых алгоритм ищет оптимальное разделение.

a) `sqrt` – в каждой вершине выбирается количество признаков, равное квадратному корню из общего числа признаков;

b) `log2` – число признаков, равное двоичному логарифму от их общего количества.

6. `random_state = 42` – произвольное число¹⁷, задаваемое программе, чтобы при каждом запуске программы конечный результат оставался неизменным.

В таблице 11 указаны найденные гиперпараметры на 3 000 000 клиентов алгоритма дерева решений двумя методами GridSearchCV и RandomizedSearchCV. С помощью найденных гиперпараметров алгоритм решающих деревьев продемонстрировал следующие результаты (см. Таблицу 12, см. Таблицу 13). Из таблицы 12 видно, что после подбора гиперпараметров методом GridSearchCV (см. Листинг 12), (см. Приложение 3) алгоритм дерева решений показал высокое качество классификации на обучающей и тестовой выборках.

¹⁵ Джини К. (1884-1965 гг.) – итальянский статистик, экономист, социолог и демограф.

¹⁶ Шеннон К.Э. (1916-2001 гг.) – американский инженер, криптоаналитик и математик, заложил основы теории информации.

¹⁷ Почему именно «42» - широко известное и запоминающееся значение по умолчанию среди исследователей. Это ответ на главный вопрос жизни, Вселенной и всего сущего в романе Дугласа Адамса «Автостопом по Галактике».

Таблица 11 – Выбор гиперпараметров для алгоритма Decision Tree по двум методам

	GridSearchCV	RandomizedSearchCV
criterion	entropy	entropy
max_depth	20	25
max_features	log2	log2
min_samples_leaf	15	10
min_samples_split	15	10
random_state	42	42

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Высокие значения precision указывают на то, что модель редко ошибочно определяет метку класса клиентов. Также значения recall демонстрируют, что модель хорошо выявляет недефолтных и дефолтных заемщиков. Значения f1-score подтверждают сбалансированность между точностью (precision) и полнотой (recall) метрик. Метрика ассигасу, равная 0.98, указывает на высокую долю верно классифицированных наблюдений, а ROC-AUC на уровне 0.98–0.99 демонстрирует высокую способность модели разделять клиентов на два класса. Близость результатов метрик позволяет сделать вывод об отсутствии выраженного переобучения модели.

Таблица 12 – Метрики точности алгоритма Decision Tree с использованием GridSearchCV

Алгоритм – Деревья решений						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Ассигасу точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.98	0.98	0.99	1438790
1	0.94	1.00	0.97			811210
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	478716
1	0.94	1.00	0.97			271284

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Для более наглядной интерпретации полученных результатов представлена матрица ошибок (см. Рисунок 18). На обучающей выборке модель допустила 2 453 ошибок при классификации недефолтных клиентов и 45 288 ошибок при классификации дефолтных клиентов. На тестовой выборке соответствующие значения составили 916 и 15 107 ошибок. Снижение неверных предсказаний на тестовой выборке объясняется меньшим объемом этой выборки. Можно заметить, что структура ошибок на обучающей и тестовой выборках остается близкой, указывая на сохранение качества классификации на тестовых данных и отсутствии выраженного переобучения.




Рисунок 18 – Результаты подбора гиперпараметров с помощью GridSearchCV

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Значения метрик, подобранные методом RandomizedSearchCV (см. Таблицу 12), (см. Листинг 13), (см. Приложение 3) остаются высокими и близкими к результатам, полученными методом GridSearchCV, поэтому основное внимание уделяется сравнению матриц ошибок.

Таблица 13 – Метрики точности алгоритма Decision Tree с использованием RandomizedSearchCV

Алгоритм – Деревья решений						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Аccuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.98	0.98	0.99	1438790
1	0.94	1.00	0.97			811210
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	478716
1	0.94	1.00	0.97			271284

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Из рисунка 19 видно, что в данном случае модель допускает меньше ошибок на обеих выборках, чем при подборе гиперпараметров с помощью метода GridSearchCV. Сравнив матрицы ошибок на двух методов выбор делается в пользу метода RandomizedSearchCV.




Рисунок 19 – Результаты подбора гиперпараметров с помощью RandomizedSearchCV

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

2.1.2. Случайный лес

Случайный лес (Random Forest) является модификацией алгоритма дерева решений. По этой причине данные алгоритмы имеют схожие гиперпараметры, кроме `n_estimators`, где `n_estimators` – это число деревьев в алгоритме случайного леса.

Таблица 14 – Выбор гиперпараметров для алгоритма Random Forest по двум методам

	GridSearchCV	RandomizedSearchCV
n_estimators	60	40
criterion	gini	entropy
max_depth	20	30
max_features	sqrt	log2
min_samples_leaf	10	10
min_samples_split	30	10
random_state	42	42

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Из таблицы 15 видно, что после подбора гиперпараметров с помощью GridSearchCV (см. Листинг 14), (см. Приложение 3) алгоритм показал высокое качество классификации на обоих выборках. Высокие значения метрик precision, recall, f1-score свидетельствуют о хорошем распознавании недефолтных и дефолтных клиентов. Значения accuracy и ROC-AUC также показывают хорошую разделяющую способность модели. Вместе с тем для класса 1 на обучающей выборке метрики немного выше, чем на тестовой, что указывает на небольшой эффект переобучения. Однако различия не являются существенными, поэтому модель сохраняет хорошую предсказательную способность.

Таблица 15 – Метрики точности алгоритма Random Forest с использованием GridSearchCV

Алгоритм – Случайный лес						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.98	0.98	0.99	1438790
1	0.94	1.00	0.97			811210
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	478716
1	0.95	1.00	0.97			271284

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Матрица ошибок (см. Рисунок 20) показывает, что алгоритм случайного леса допускает меньше ошибочных предсказаний в отличие от алгоритма Decision Tree. Число ошибок также сохраняет равномерное соотношение 3 к 1, что указывает на хорошую устойчивость модели при классификации наблюдений.




Рисунок 20 – Результаты подбора гиперпараметров с помощью GridSearchCV

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Из таблицы 16 видно, что алгоритм с гиперпараметрами, подобранными методом RandomizedSearchCV (см. Листинг 15), (см. Приложение 3) сохраняет высокое качество классификации на обеих выборках.

Таблица 16 – Метрики точности алгоритма Random Forest с использованием RandomizedSearchCV

Алгоритм – Случайный лес						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.98	0.98	1.00	1438790
1	0.94	1.00	0.97			811210
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	478716
1	0.94	1.00	0.97			271284

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Матрица ошибок (см. Рисунок 21) показывает, что модель с гиперпараметрами, подобранными методом RandomizedSearchCV, допускает больше ошибок по классу 0 в отличие от варианта GridSearchCV. Тем не менее общее число ошибок выше, чем при GridSearchCV, поэтому в данном случае целесообразно выбрать гиперпараметры, найденные с помощью GridSearchCV.




Рисунок 21 – Результаты подбора гиперпараметров с помощью RandomizedSearchCV

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

2.1.3. Градиентный бустинг

В данной работе для алгоритма градиентного бустинга (Gradient Boosting) использовались гиперпараметры по умолчанию. В отличие от алгоритмов Decision Tree и Random Forest, для которых гиперпараметры подбирались методами GridSearchCV и RandomizedSearchCV, базовая настройка модели обеспечила высокое качество классификации. В связи с этим дополнительный подбор гиперпараметров не проводился, и далее рассматриваются полученные метрики точности модели.

Метрики точности (см. Таблицу 17) свидетельствуют о высоком качестве классификации данного алгоритма. Значения метрик precision, recall, f1-score по обоим классам остаются высокими на двух выборках. Показатели accuracy и ROC-AUC также подтверждают хорошую разделяющую способность модели. При этом выраженный эффект переобучения не наблюдается, поскольку значения метрик на обучающей и тестовой выборках практически совпадают.

Таблица 17 – Метрики точности алгоритма Gradient Boosting с гиперпараметрами по умолчанию

Алгоритм – Градиентный бустинг						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	0.99	0.97	0.98	0.98	0.98	1438790
1	0.95	0.99	0.97			811210
Тестовая выборка						
0	0.99	0.97	0.98	0.98	0.98	478716
1	0.95	0.99	0.97			271284

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Матрица ошибок (см. Рисунок 22) подтверждает результаты метрик таблицы 17. Большинство наблюдений на тренировочной и тестовой выборке верно классифицировано, однако число ошибок в данном случае больше, чем у алгоритмов дерева решений и случайного леса.




Рисунок 22 – Результаты качества классификации с гиперпараметрами по умолчанию алгоритма Gradient Boosting

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

На обучающей выборке модель неверно отнесла 7 708 недефолтных клиентов к классу 1 и 44 452 дефолтных клиентов к классу 0, а на тестовой выборке 2 597 и 14 745

соответственно. В выборках структура ошибок остается близкой, что также указывает на отсутствие выраженного переобучения. Таким образом, градиентный бустинг показывает высокое качество классификации наблюдений, но уступает по числу ошибок ранее рассмотренным моделям.

2.1.4. Нейронная сеть

Для классификации клиентов используется однослойная нейронная сеть, состоящая из входного слоя размерности 19 признаков, одного скрытого слоя из 32 нейронов с функцией активации ReLU и выходного слоя с функцией sigmoid, заложенного в основе формирования вероятности дефолта. Для нейронной сети основными параметрами обучения являются:

1. `epochs` – число эпох обучения нейронной сети. Параметр показывает, сколько раз модель обучается по всей обучающей выборке. Если число эпох слишком мало, то нейронная сеть будет недообучена и неспособна выявить закономерности в данных. В данном случае используется 20 эпох, поскольку является достаточным для обучения модели.

2. `batch_size` – размер пакета данных, на котором модель обучается за один шаг обучения. Например, `batch_size = 128` означает, что на одном шаге модель обрабатывает 128 клиентов, выбранных в случайном порядке из обучающей выборки.

3. `Dense(32)` – скрытый слой нейронной сети, состоящий из 32 нейронов. Каждый нейрон формирует собственную комбинацию входных признаков, позволяющие модели выявлять скрытые зависимости между характеристиками клиента и вероятностью дефолта.

4. `activation = ReLU` – функция активации скрытого слоя. Функция ReLU преобразует отрицательные числа в ноль, а положительные значения остаются без изменения, что позволяет алгоритму выявлять наиболее значимые комбинации признаков и создавать более сложные зависимости между входными данными и целевым признаком.

5. `Dense(1)` – выходной слой, состоящий из одного нейрона. В данной работе решается задача бинарной классификации, поэтому на выходе используется только 1 нейрон, который формирует конечную оценку клиента о принадлежности к классу 0 или 1.

6. `activation = sigmoid` – функция активации выходного слоя. Сигмоидальная функция преобразует входные значения в диапазон (0; 1) и выводит вероятность дефолта.

7. `optimizer = Adam` – оптимизатор, с помощью которого нейронная сеть обновляет свои веса в процессе обучения. После каждого шага обучения модель сравнивает свой прогноз с фактическим значением и корректирует веса связей между нейронами.

8. `learning_rate = 0.005` – шаг обучения модели.

9. `loss = mse` – функция потерь, которая показывает насколько прогнозы модели отличаются от фактических значений целевого признака.

10. `BinaryAccuracy` – метрика точности классификации. Показывает долю верно классифицированных наблюдений. Порог `threshold = 0.5` означает, что при вероятности выше 0.5 клиент относится к классу дефолтных, а ниже – к классу недефолтных клиентов.

Нейронная сеть показывает высокое качество классификации на обеих выборках

(см. Таблицу 18). Метрики precision, recall, f1-score показывают хорошее распознавание недефолтных и дефолтных клиентов. Значения accuracy = 0.98 и ROC-AUC = 0.97 также свидетельствуют о хорошей разделяющей способности модели. Значения всех метрик практически совпадают, что говорит об отсутствии выраженного эффекта переобучения.

Таблица 18 – Метрики точности алгоритма Neural Network

Нейронная сеть						
Flag метка	Precision точность	Recall полнота	f1-score f1-мера	Accuracy точность	ROC-AUC	Количество
Тренировочная выборка						
0	0.99	0.97	0.98	0.98	0.97	1438790
1	0.95	0.99	0.97			811210
Тестовая выборка						
0	0.99	0.97	0.98	0.98	0.97	478716
1	0.95	0.99	0.97			271284

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025). Загл. с экрана.

Результаты обучения нейронной сети показывают (см. Рисунок 23), что уже к 5 эпохе точность алгоритма на тренировочной и тестовой выборках (accuracy) возрастает, а затем выходит на устойчивый уровень. Параллельно значения функции потерь на обеих выборках снижаются к 5 эпохе и стабилизируются, что также указывает на отсутствие эффекта переобучения.




Рисунок 23 – Результаты обучения нейронной сети на тренировочной и тестовой выборках

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Матрица ошибок (см. Рисунок 24) также подтверждает, что большинство наблюдений в выборках были правильно классифицированы, но можно заметить, что допускает больше ошибочных предсказаний, чем алгоритм дерева решений (Decision Tree) и случайного леса

(Random Forest). При этом соотношение ошибок на обеих выборках остается близким, что указывает на отсутствие эффекта переобучения.




Рисунок 24 – Результаты обучения нейронной сети на тренировочной и тестовой выборке

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. URL: <https://ods.ai/competitions/dl-fintech-bki> (дата обращения: 25.11.2025).

Несмотря на то, что все модели продемонстрировали высокое качество классификации, исходя из рассмотренных результатов метрик точности, матрицы ошибок позволили более точно распознать количество ошибочных предсказаний. Таким образом, сравнив ошибочные результаты классификаций, наиболее лучшей моделью является алгоритм случайного леса, поскольку он допускает меньше ошибок.

2.2. Ограничения и возможности моделей

На основе проделанной работы в рамках данного датасета можно выделить существенные ограничения и дальнейшие возможности работы моделей при прогнозировании кредитного риска заемщиков. Под ограничениями работы с моделями ИИ понимаются проблемы технического и нормативного характера.

Во-первых, одной из ключевых проблем являются вычислительные ресурсы. Модели дерева решений, случайного леса, градиентного бустинга и нейронной сети требуют значительных вычислительных мощностей при обработке 3 млн данных клиентов банка, что увеличивает длительность обработки на одном алгоритме до нескольких дней. Подбор оптимальных гиперпараметров для улучшения прогностических способностей алгоритмов также может длиться около недели. Если расширить масштаб анализа на всю банковскую систему Казахстана, где, по данным ПКБ, около 9 млн¹⁸ экономически активного населения имеют кредиты, то требования к вычислительным ресурсам возрастают многократно. Решением может быть либо улучшение IT-инфраструктуры, либо переход на облачные технологии.

¹⁸Свыше 9 млн казахстанцев имеют кредиты на сумму больше 24 трлн тенге [Электронный ресурс] / Информационный портал 24.kz. – URL: <https://24.kz/ru/news/social/729252-svyshe-9-mln-kazakhstansev-i-meyut-kredity-na-summu-bolshe-kzt24-trln> (дата обращения: 6.03.2026). Загл. с экрана.

Во-вторых, качество работы моделей зависит от экономической среды вместе с которой изменяется и потребительское поведение заемщиков. Поэтому модель, обученная на данных предыдущих периодов, может давать систематические ошибки в прогнозировании дефолта. Следовательно, необходимо регулярно обновлять данные кредитных историй и переобучать модели на обновленных данных либо адаптировать входные данные к уже обученным моделям. Под такой адаптацией понимается преобразование новых данных к такому виду, на котором модели ранее обучались, чтобы сохранить качество прогноза моделей. Кроме этого для улучшения точности предсказаний необходимы такие дополнительные признаки, среди которых первые 3 признака были использованы в курсовой работе¹⁹:

1. счет на оплату кредита за каждый месяц;
2. фактическая оплата счета за каждый месяц;
3. объем кредита;
4. оплата коммунальных услуг (объем счета, объем фактической оплаты, платежная дисциплина);
5. заработная плата и пенсионные отчисления;
6. количество несовершеннолетних детей.

В-третьих, для качественного прогноза модели помимо кредитных историй можно также анализировать альтернативные данные. Однако доступ к ним ограничен с целью защиты персональных данных клиентов. Кроме того, у каждого банка накапливается лишь часть кредитной истории, поскольку кредиты одного заемщика могут быть оформлены в разных банках. Поэтому невозможно объединить все кредитные истории со всех банков в единую систему для анализа, поскольку необходимо получить разрешение от всех клиентов. Таким образом, каждый банк вынужден разрабатывать собственные подходы к оценке кредитоспособности заемщиков на основе ограниченного массива доступных банку данных. Создание единой межбанковской системы на основе ИИ, которая могла бы анализировать полную долговую нагрузку клиента, ограничивается правовыми барьерами.

Под возможностями моделей ИИ понимается их предсказательная способность, характеризующаяся метриками точности. Следует отметить, что прогноз модели напрямую зависит от того, насколько корректно определено понятие аномального клиента. Например, в курсовой работе²⁰, где исследовались данные кредитных историй по Республике Тайвань, метрики точности оказались ниже, чем в данной работе. По этой причине, следует внимательно относиться к предобработке данных, потому что качество их подготовки во многом определяет конечный результат прогноза моделей ИИ.

¹⁹Касенова А.А. Указ. соч. С. 5.

²⁰Касенова А.А. Указ. соч. С. 22.

ЗАКЛЮЧЕНИЕ

В условиях цифровизации финансового сектора и роста долговой нагрузки населения, коммерческим банкам необходимо более точно и быстро оценивать кредитоспособность заемщиков. Традиционный подход к их оценке не способен выявлять сложные нелинейные зависимости в характеристиках клиента, а современный подход с применением моделей МО и ГО, наоборот, позволяет их выявить и повысить качество прогнозирования дефолта. Для достижения поставленной цели было проделано следующее:

1. в главе 1 изучены теоретические подходы к кредитному скорингу, дано определение на основе анализа научной литературы, рассмотрены статьи закона «Об искусственном интеллекте», косвенно затрагивающих применение ИИ в кредитном скоринге;

2. в главе 2 проведен анализ исходных обезличенных данных кредитных историй АО «Альфа-Банка», проведены предобработка данных и сокращение признакового пространства, введено и обосновано определение аномального клиента и далее протестированы модели МО и ГО на 1 миллионе клиентов;

3. в главе 3 данные модели были протестированы на больших данных и проведено сравнение оценки качества моделей МО и ГО.

В процессе исследования было установлено, что прогностическая способность моделей в большей степени зависит именно от качества подготовки данных, в отличие от подбора использования самих моделей. Значимым результатом данной работы является введение понятия аномального клиента как заемщика с фактической меткой недефолтного (платежеспособного) клиента, но при этом его платежная дисциплина схожа с платежным поведением дефолтных (неплатежеспособных) клиентов. Гипотеза о том, что аномальные клиенты по своему поведению схожи с дефолтными клиентами была подтверждена в результате статистической проверки теста Колмогорова-Смирнова. Проведенная переклассификация позволила качественно подготовить данные заемщиков для последующего моделирования. Все рассмотренные алгоритмы продемонстрировали высокие метрики точности.

Результаты показали, что наилучшими алгоритмами в данном исследовании являются деревья решений и случайный лес. Эти модели показали меньшее количество ошибочных предсказаний по сравнению с градиентным бустингом и нейронной сетью. При этом следует отметить, что дополнительный подбор гиперпараметров для градиентного бустинга не потребовался, поскольку изначально данный алгоритм не выявил эффекта переобучения по сравнению с деревьями решений и случайным лесом. Поэтому в данном случае алгоритм градиентного бустинга является наиболее устойчивым

Также метрики качества моделей по выявлению дефолтных клиентов оказались немного ниже, чем для недефолтных. Отсюда следует вывод, что распознавание неплатежеспособных заемщиков является более трудоемкой задачей по сравнению с выявлением платежеспособных.

Практическая значимость работы заключается в том, что рассмотренные алгоритмы машинного и глубокого обучения могут достаточно точно прогнозировать риски дефолта (недефолта) по кредитным обязательствам в банковской сфере. Ценность исследования заключается в предложении подхода по выявлению аномальных клиентов, позволяющий выявить скрытую группу неплатежеспособных заемщиков, которые представляют существенный риск. Это даст возможность более точно прогнозировать риски при выдаче кредита. Результаты исследования могут быть использованы в Первом кредитном бюро Республики Казахстан для повышения эффективности принятия кредитных решений, а также выдачи кредитных карт посредством анализа кредитной истории заемщиков.

СПИСОК ЛИТЕРАТУРЫ

Нормативные акты:

1. Об искусственном интеллекте [Электронный ресурс] : [закон Республики Казахстан от 17 ноября 2025 г. № 230-VIII : по состоянию на 6 марта 2026 г.]. – URL: https://prg.kz/document/?doc_id=33297881. – Доступ из информационной системы «Параграф».

Книги:

2. Вандер Плас, Дж. Python для сложных задач: наука о данных и машинное обучение / Дж. Вандер Плас. – СПб. : Питер, 2018. – 576 с. – URL: https://iro23.ru/sites/default/files/plas_dzh_vander_-_python_dlya_slozhnyh_zadach_nauka_o_dannyh_i_mashinnoe_obuchenie_bestsellery_oreilly_-_2018.pdf.

3. Рашка, С. Python и машинное обучение: машинное и глубокое обучение с использованием Python, scikit-learn и TensorFlow 2 / С. Рашка, В. Мирджалили; пер. с англ. Ю.Н. Артеменко. – СПб. : Диалектика, 2020. – 846 с. – URL: <https://library.cbr.ru/catalog/lib/books/388311/>.

Статьи:

4. Бобкова, Е. А. Применение искусственного интеллекта в банковской сфере: технологии и результаты: выпускная квалификационная работа : 38.03.01 / Бобкова Екатерина Андреевна. Санкт-Петербург, 2025. – С. 1 – 72. – URL: <https://ru.scribd.com/document/1029392789/Bobkova-E-a-21-B06-E-Primenenie-Iskusstvennogo-Intellekta-v-Bankovskoj-Sfere-Tehnologii-i-Rezultaty>.

5. Гозгешев, Э. А. Искусственный интеллект в банковском секторе: возможности и риски // Вестник евразийской науки. – 2024. – № 6, том 16. – С. 1 – 9. – URL: <https://esj.today/PDF/49FAVN624.pdf>.

6. Городецкая, О. Ю. Ключевые тренды применения искусственного интеллекта в банковской сфере / О. Ю. Городецкая, Я. Л. Гобарева // Финансовые рынки и банки. – 2022. – № 12. – С. 34 – 42. – URL: <https://cyberleninka.ru/article/n/klyuchevye-trendy-primeneniya-iskusstvennogo-intellekta-v-bankovskoy-sfere>.

7. Зиятбекова, Г. З. Исследование систем кредитного скоринга с использованием алгоритмов машинного обучения / Г. З. Зиятбекова, Д. К. Даркенбаев, Д. К. Алтыбай, А. Даркенбаев, Н. О. Мекебаев // КазУТБ. – 2024. – том 3. – С. 1 – 11. – URL: https://www.researchgate.net/publication/401753914_ISSLEDOVANIE_SISTEM_KREDITNOGO_SKORINGA_S_ISPOLZOVANIEM_ALGORITMOV_MASINNOGO_OBUCENIA.

8. Касенова, А. А. Определение кредитного скоринга заемщиков банка на основе технологии машинного обучения : курсовая работа : 38.03.01 / Касенова Асем Ардаккызы. Москва, 2025. – С. 1 – 27.

9. Лемешко, Б. Ю. О распределениях статистик и мощности критериев однородности двух выборок / Б. Ю. Лемешко, С. Б. Лемешко // Материалы Российской НТК «Информатика и проблемы коммуникаций». – 2005. – том 1. – С. 109–112. – URL: https://ami.nstu.ru/~headrd/seminar/publik_html/popov_2005_1.pdf.
10. Лемешко, Б. Ю. Исследование распределения оценок коэффициента корреляции в зависимости от истинного значения корреляции / А. В. Танасейчук, Б. Ю. Лемешко // Материалы VIII международной конференции «Актуальные проблемы электронного приборостроения» АПЭП-2006. – 2006. – том 6. – С. 91–94. – URL: http://www.ami.nstu.ru/~headrd/seminar/publik_html/APEP2006_4.htm.
11. Михайлов, Д. И. Применение методов искусственного интеллекта в системе риск-менеджмента банка // Научные записки молодых исследователей. – 2025. – № 13, том 3. – С. 55 – 61. – URL: <https://cyberleninka.ru/article/n/primenenie-metodov-iskusstvennogo-intellekta-v-sisteme-risk-menedzhmenta-banka>.
12. Смирнов, С. В. Методы машинного обучения в макроэкономическом прогнозировании: предварительные итоги // Вопросы экономики. – 2025. – № 10. – С. 131 – 154. – URL: <https://www.vopreco.ru/jour/article/view/5470>.
13. Addy, W. A. AI in credit scoring: A comprehensive review of models and predictive analytics / W. A. Addy, A. O. Ajayi-Nifise, B. G. Bello, S. T. Tula, O. Odeyemi, T. Falaiye // Global Journal of Engineering and Technology Advances. – 2024. – Vol. 18, № 2. – P. 118 – 129. – URL: https://www.researchgate.net/publication/378311289_AI_in_credit_scoring_A_comprehensive_review_of_models_and_predictive_analytics.
14. Bari, H. A systematic literature review of models and predictive analytics / H. Bari, S. Juthi, A. M. Mistry, M. Kamrujjaman // Journal of machine learning, data engineering and data science. – 2024. – Vol. 1, № 1. – P. 1 – 18. – URL: https://www.researchgate.net/publication/385565339_A_SYSTEMATIC_LITERATURE_REVIEW_OF_PREDICTIVE_MODELS_AND_ANALYTICS_IN_AI-DRIVEN_CREDIT_SCORING.
15. Fisher, R. A. Frequency Distribution of the Values of the Correlation Coefficient in Samples from an Indefinitely Large Population // Biometrika. – 1915. – Vol.10, № 4. – P. 507 – 521. – URL: <https://www2.stat.duke.edu/courses/Spring05/sta215/lec/Fish1915.pdf>.
16. Kothandapani, H. P. Leveraging AI for credit scoring and financial inclusion in emerging markets // World Journal of Advanced Research and Reviews. – 2022. – Vol. 15, № 3. – P. 526 – 539. – URL: https://www.researchgate.net/publication/388359465_Leveraging_AI_for_credit_scoring_and_financial_inclusion_in_emerging_markets.
17. Mehndiratta, N. The use of Artificial Intelligence in the Banking Industry / N. Mehndiratta, G. Arora, R. Bathla // International Conference on Recent Advances in Electrical, Electronics & Digital Healthcare Technologies (REEDCON). – 2023. – P. 588 – 591. – URL: https://www.researchgate.net/publication/372671363_The_Use_of_Artificial_Intelligence_in_Banking_Industry.

18. Nuka, T. F. AI and machine learning as tools for financial inclusion: challenges and opportunities in credit scoring / T. F. Nuka, A. A. Ogunola // International Journal of Science and Research Archive. – 2024. – Vol. 13, № 2. – P. 1052 – 1067. – URL: [AIandmachinelearningastool sforfinancialinclusion:challengesandopportunitiesincreditscoring](#).

19. Omotosho, M. Exploring the role of AI-driven credit scoring systems on financial inclusion in emerging economies // American Journal of Humanities and Social Sciences Research. – 2025. – Vol. 9. – P. 1 – 10. – URL: https://www.researchgate.net/publication/388842627_EXP_LORING_THE_ROLE_OF_AI-DRIVEN_CREDIT_SCORING_SYSTEMS_ON_FINANCIAL_INCLUSION_IN_EMERGING_ECONOMIES.

20. Vakrani, D.S. Evaluating AI-driven credit scoring models versus traditional statistical techniques / D. S. Vakrani, P. S. Padhye, S. K. Gupta, J. K. Roy, V. S. Nerlekar, N. Parashar // Discover Artificial Intelligence. – 2026. – Vol. 6. – P. 1 – 14. – URL: https://www.researchgate.net/publication/399114523_Evaluating_AI-driven_credit_scoring_models_versus_traditional_statistical_techniques.

21. Wang, H. Application of Decision Tree Model in Personal Credit Scoring and Its Fairness Optimization // Advances in Economics, Management and Political Sciences. – 2025. – Vol. 176. – P. 109 – 118. – URL: https://www.researchgate.net/publication/390979182_Application_of_Decision_Tree_Model_in_Personal_Credit_Scoring_and_Its_Fairness_Optimization.

Интернет-ресурсы:

22. Забытые долги казахстанцев перед банками выросли в полтора раза за год [Электронный ресурс] / Общественно-политическое издание kursiv.kz. – URL: <https://kz.kursiv.media/2026-03-02/fvfv-zabytyye-dolgi-kazakhstantsev-pered-bankami-vyrosli-v-poltora-razaza-za-god/>. – Загл. с экрана.

23. Искусственный интеллект и его применение в банковском секторе [Электронный ресурс] / Национальный Банк Республики Беларусь. – URL: <https://www.nbrb.by/bv/pdf/articles/12217.pdf>. – Загл. с экрана.

24. Искусственный интеллект на финансовых рынках Центральной Азии. Текущее состояние и перспективы [Электронный ресурс] / Национальный Банк Республики Казахстан. – URL: <https://nationalbank.kz/ru/news/analitika-metodologiya/rubrics/2211>. – Загл. с экрана.

25. Казахстанцев ждет долговая усталость в 2026 году: экономист озвучил опасения [Электронный ресурс] / Общественно-политическое издание kursiv.kz – URL: <https://kz.kursiv.media/2026-01-27/svan-kazahstancy-prodolzhayut-popolnyat-depozity-i-brat-novye-kredity-nesmotrya-na-stavku/>. – Загл. с экрана.

26. Казахстан занимает 76-е место в списке стран с наибольшей готовностью к развитию искусственного интеллекта [Электронный ресурс] / Казахстанское международное информационное агентство. – URL: <https://cn.inform.kz/news/zairengongnengfazhongdi76-fed5aa/>. – Загл. с экрана.

27. Как использовать машинное обучение для принятия решений о кредитовании? [Электронный ресурс] / Аутсорсинговая компания Invento Labs. – URL: <https://invento-labs.by/o-kompanii/blog/2024/jan/kak-ispolzovat-mashinnoe-obuchenie-dlya-prinyatiya-reshenij-o-kreditovanii.html>. – Загл. с экрана.
28. Как работает метод главных компонент (PCA) – на простом примере [Электронный ресурс] / Яндекс Практикум. – URL: <https://practicum.yandex.ru/blog/metod-glavnyh-komponent/>. – Загл. с экрана.
29. Ловушка в 20%: почему казахстанцы продолжают кредитоваться при падающих доходах [Электронный ресурс] / Информационный портал РК. – URL: <https://www.zakon.kz/finansy/6505800-lovushka-v-20-pochemu-kazakhstantsy-prodolzhayut-kreditovatsya-pri-padayushchikh-dokhodakh.html>. – Загл. с экрана.
30. Можно ли «отбелить» кредитную историю и есть ли черный список должников в Казахстане [Электронный ресурс] / Информационный интернет-портал «Tengrinews». – URL: https://tengrinews.kz/kazakhstan_news/li-otbelit-kreditnuyu-istoriyu-est-chnyiy-spisok-doljnikov-560869/. – Загл. с экрана.
31. Полное руководство по автоматизированному кредитному скорингу: глубокое погружение в ИИ, машинное обучения и будущее финансовых решений [Электронный ресурс] / Emagia. – URL: <https://www.emagia.com/ru/resources/glossary/automated-credit-scoring/>. – Загл. с экрана.
32. Свыше 9 млн казахстанцев имеют кредиты на сумму больше 24 трлн тенге [Электронный ресурс] / Информационный портал 24.kz. – URL: <https://24.kz/ru/news/social/729252-svyshe-9-mln-kazakhstantsev-imeyut-kredity-na-summu-bolshe-kzt24-trln>. – Загл. с экрана.
33. Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: <https://ods.ai/competitions/dl-fintech-bki>. – Загл. с экрана.
34. GridSearchCV [Электронный ресурс] / Python-библиотека для машинного обучения. – URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. – Загл. с экрана.
35. PCA [Электронный ресурс] / Python-библиотека для машинного обучения. – URL: <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>. – Загл. с экрана.
36. RandomizedSearchCV [Электронный ресурс] / Python-библиотека для машинного обучения. – URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.RandomizedSearchCV.html. – Загл. с экрана.
37. Government AI Readiness Index 2025 [Электронный ресурс] / Британская аналитическая и консалтинговая компания «Oxford Insights». – URL: https://oxfordinsights.com/wp-content/uploads/2026/01/2025-Government-AI-Readiness-Index-Report_01_26.pdf. – Загл. с экрана.

Листинг 1 – Формирование единого датасета

```
1 import pandas as pd
2 import os
3 import pyarrow.parquet as pq
4 path = "train_data"
5 for i,file in enumerate(os.listdir(path)):
6     print('train_data_' + str(i) + '.pq')
7     file = 'train_data_' + str(i) + '.pq'
8     dataset = pq.ParquetDataset(os.path.join(path,file))
9     df = dataset.read(use_threads=True).to_pandas()
10    df_gr = df.groupby('id').agg('mean')
11    file_csv = file.replace('.pq', '.csv')
12    df_gr.to_csv(os.path.join('train_data_csv_all',file_csv))
13 os.listdir(path)
14 path = 'train_data_csv_all'
15 frames = []
16 for i,file_csv in enumerate(os.listdir(path)):
17     file_csv = 'train_data_' + str(i) + '.csv'
18     print(file_csv)
19     df = pd.read_csv(os.path.join('train_data_csv_all',file_csv))
20     frames.append(df)
21 result = pd.concat(frames)
22 file_csv_all = '1_data_csv_all_general.csv'
23 result.to_csv(file_csv_all)
```

Листинг 2 – Датасет, содержащий 41 признак

```

1 from sklearn.decomposition import PCA
2 file_csv_all = '1_data_csv_all_general.csv'
3 df = pd.read_csv(file_csv_all)
4 columns = ['pre_pterm', 'pre_fterm', 'pre_loans_next_pay_summ',
5            'pre_loans_outstanding', 'pre_loans_total_overdue',
6            'pre_loans_max_overdue_sum', 'pre_loans_credit_cost_rate',
7            'is_zero_loans5', 'is_zero_loans530', 'is_zero_loans3060',
8            'is_zero_loans6090', 'is_zero_loans90', 'pre_util',
9            'pre_maxover2limit', 'is_zero_util', 'is_zero_over2limit',
10           'enc_paym_0', 'enc_paym_1', 'enc_paym_2',
11           'enc_paym_3', 'enc_paym_4', 'enc_paym_5',
12           'enc_paym_6', 'enc_paym_7', 'enc_paym_8',
13           'enc_paym_9', 'enc_paym_10', 'enc_paym_11',
14           'enc_paym_12', 'enc_paym_13', 'enc_paym_14',
15           'enc_paym_15', 'enc_paym_16', 'enc_paym_17',
16           'enc_paym_18', 'enc_paym_19', 'enc_paym_20',
17           'enc_paym_21', 'enc_paym_22', 'enc_paym_23', 'enc_paym_24']
18 X_pay = df.loc[:1000000, columns].copy()
19 pca = PCA()
20 pca.fit(X_pay)
21 100*pca.explained_variance_ratio_.round(3)

```

Листинг 3 – Датасет, содержащий 25 признаков

```

1 file_csv_all_25 = '2_data_csv_all_25.csv'
2 df_all_25 = pd.read_csv(file_csv_all_25)
3 columns_pay_25 = ['enc_paym_0', 'enc_paym_1', 'enc_paym_2',
4                  'enc_paym_3', 'enc_paym_4', 'enc_paym_5',
5                  'enc_paym_6', 'enc_paym_7', 'enc_paym_8',
6                  'enc_paym_9', 'enc_paym_10', 'enc_paym_11',
7                  'enc_paym_12', 'enc_paym_13', 'enc_paym_14',
8                  'enc_paym_15', 'enc_paym_16', 'enc_paym_17',
9                  'enc_paym_18', 'enc_paym_19', 'enc_paym_20',
10                 'enc_paym_21', 'enc_paym_22', 'enc_paym_23',
11                 'enc_paym_24']
12 X_pay_25 = df_all_25.loc[:1000000, columns_pay_25].copy()
13 pca = PCA()
14 pca.fit(X_pay_25)
15 100*pca.explained_variance_ratio_.round(3)

```

Листинг 4 – Алгоритм выявления аномальных клиентов

```

1 df_y = pd.read_csv('train_target.csv')
2 y = df_y.flag.values[:1000001]
3 y_ = df_y.flag.values[:1000001]
4 counter_norm, counter_anom = 0, 0
5 ind_norm, ind_anom = [], []
6 for i,x_pay in enumerate(np.array(X_pay_25)):
7     if y_[i]==0 and min(x_pay)>0:
8         counter_anom +=1
9         ind_anom.append(i)
10        y_[i]=1
11    else:
12        counter_norm +=1
13        ind_norm.append(i)
14 print(f'amount_of_anomal_customer={counter_anom}')
15 print(f'amount_of_normal_customer={counter_norm}')

```

Листинг 5 – Критерий Колмогорова-Смирнова

```

1 col = 'enc_paym_14'
2 T = X_pay_25.enc_paym_14
3 x00, x01, x11 = T[(y==0) & (y_== 0)], T[ind_anom], T[(y==1)]
4 ind00 = (x00!=0)&(x00!=1)&(x00!=2)&(x00!=3)&(x00!=4)&(x00!=5)
5 ind01 = (x01!=0)&(x01!=1)&(x01!=2)&(x01!=3)&(x01!=4)&(x01!=5)
6 ind11 = (x11!=0)&(x11!=1)&(x11!=2)&(x11!=3)&(x11!=4)&(x11!=5)
7 x00, x11, x01 = x00[ind00], x11[ind11], x01[ind01]
8 def my_cdf(x1, x2, step):
9     tm = max(max(x1), max(x2))
10    F1,F2 = [], []
11    n1, n2 = x1[x1>0].shape[0], x2[x2>0].shape[0]
12    for t in np.arange(0, tm+0.1, step):
13        F1.append(x1[(x1>0)&(x1<t)].shape[0])
14        F2.append(x2[(x2>0)&(x2<t)].shape[0])
15    F1, F2 = np.array(F1)/n1, np.array(F2)/n2
16    K = max(abs(F1-F2))*np.sqrt(n1*n2/(n1+n2))
17    return F1, F2, K, tm
18 step = 0.01
19 F01, F11, K, tm = my_cdf(x01, x11, step)
20 F01_, F00, K_, tm_ = my_cdf(x01, x00, step)
21 K, K_

```


Листинг 6 – Выявление сильно коррелирующих соседних признаков

```

1 col1 = X_pay_25.enc_paym_24
2 col2 = X_pay_25.enc_paym_23
3 all_c, nod_c, def_c, ano_c, an2_c = [], [], [], [], []
4 month = []
5 for i in range( 1, X_pay_25.shape[1] ):
6     all_c.append(np.corrcoef(np.array(X_pay_25).T[i-1],
7     np.array(X_pay_25).T[i] )[0,1])
8     ind_nod = np.where(y==0)[0]
9     nod_c.append(np.corrcoef(np.array(X_pay_25).T[i-1][ind_nod],
10    np.array(X_pay_25).T[i][ind_nod] )[0,1] )
11    ind_def = np.where(y==1)[0]
12    def_c.append(np.corrcoef(np.array(X_pay_25).T[i-1][ind_def],
13    np.array(X_pay_25).T[i][ind_def] )[0,1] )
14    ind_ano = ind_anom
15    ano_c.append(np.corrcoef(np.array(X_pay_25).T[i-1][ind_ano],
16    np.array(X_pay_25).T[i][ind_ano] )[0,1] )
17    month.append(i)
18 fig, (ax) = plt.subplots(figsize = (7, 7), dpi = 80)
19 ax.plot( month, all_c, color = 'blue', label = 'corr_all' )
20 ax.plot( month, nod_c, color = 'red', label = 'corr_noddefault' )
21 ax.plot( month, def_c, color = 'green',label = 'corr_default' )
22 ax.plot( month, ano_c, color = 'black',label = 'corr_anom' )
23 ax.grid()
24 ax.legend()
25 ax.set_xlabel('month')
26 ax.set_ylabel('correlation')

```

Листинг 7 – Тест Фишера на равенство коэффициентов корреляции выборочной и генеральной совокупностей

```
1 def transform_f(r, R, n):
2     if n > 3:
3         return 0.5*np.log(((1+r)/(1-r))*((1-R)/(1+R)))*np.sqrt(n-3)
4     else:
5         return 0
6 transform_f(r11, r11, n11), transform_f(r00, 0.99, n00)
7 mth = 23
8 n_all, n_nod = X_pay.shape[0], len(ind_nod)
9 n_def, n_ano = len(ind_def), len(ind_ano)
10 R_all, r_nod, r_def, r_ano = all_c[mth], nod_c[mth]
11 r_def, r_ano = def_c[mth], ano_c[mth]
12 transform_f(r_nod, R_all, n_nod), transform_f(r_def, R_all, n_def),
13 transform_f(r_ano, R_all, n_ano)
```

Листинг 8 – Алгоритм Decision Tree на 1 000 000 данных

```

1 from sklearn.tree import DecisionTreeClassifier
2 X_train, X_test, Y_train, Y_test = train_test_split(X_pay, y_,
3                                                     test_size=0.25,
4                                                     random_state=0)
5 dtree = DecisionTreeClassifier()
6 dtree.fit(X_train, Y_train)
7 y_pred_train = dtree.predict(X_train)
8 y_pred_test = dtree.predict(X_test)
9 print(classification_report(Y_train, y_pred_train))
10 print(classification_report(Y_test, y_pred_test))

```

Листинг 9 – Алгоритм Random Forest на 1 000 000 данных

```

1 from sklearn.ensemble import RandomForestClassifier
2 X_train, X_test, Y_train, Y_test = train_test_split(X_pay, y_,
3                                                     test_size=0.25,
4                                                     random_state=0)
5 rfc = RandomForestClassifier()
6 rfc.fit(X_train, Y_train)
7 y_pred_train = rfc.predict(X_train)
8 y_pred_test = rfc.predict(X_test)
9 print(classification_report(Y_train, y_pred_train))
10 print(classification_report(Y_test, y_pred_test))

```

Листинг 10 – Алгоритм Gradient Boosting на 1 000 000 данных

```

1 from sklearn.ensemble import GradientBoostingClassifier
2 X_train, X_test, Y_train, Y_test = train_test_split(X_pay, y_,
3                                                     test_size=0.25,
4                                                     random_state=0)
5 boost_gr = GradientBoostingClassifier()
6 boost_gr.fit(X_train, Y_train)
7 y_pred_train = boost_gr.predict(X_train)
8 y_pred_test = boost_gr.predict(X_test)
9 print(classification_report(Y_train, y_pred_train))
10 print(classification_report(Y_test, y_pred_test))

```

Листинг 11 – Алгоритм Neural Network на 1 000 000 данных

```

1 from tensorflow.keras.layers import Dense
2 y = y_
3 features = X_pay.shape[1]
4 X_train, X_test, Y_train, Y_test = train_test_split(X_pay, y_,
5                                                     test_size=0.25,
6                                                     random_state=0)
7 epochs = 20
8 model = keras.Sequential()
9 model.add(keras.Input(shape=(features,)))
10 model.add(Dense(32, activation='relu'))
11 model.add(keras.layers.Dense(1, activation='sigmoid'))
12 opt = keras.optimizers.Adam(learning_rate=0.005)
13 metrics = keras.metrics.BinaryAccuracy(name="accuracy",
14                                       dtype=None,
15                                       threshold=0.5)
16 model.compile(optimizer=opt, loss='mse', metrics=metrics)
17 fit_history = model.fit(X_train, Y_train,
18                       batch_size=128,
19                       validation_data=(X_test, Y_test),
20                       epochs=epochs)

```

Листинг 12 – Алгоритм Decision Tree с подобранными гиперпараметрами методом *GridSearchCV* на 3 000 000 данных

```

1 dtree = DecisionTreeClassifier(criterion='entropy',
2                               max_depth=20,
3                               max_features='log2',
4                               min_samples_leaf=15,
5                               min_samples_split=15,
6                               random_state=42)
7 dtree.fit(X_train, Y_train)
8 dtree.score(X_train, Y_train), dtree.score(X_test, Y_test)
9 y_pred_train = dtree.predict(X_train)
10 y_pred_test = dtree.predict(X_test)
11 print(classification_report(Y_train, y_pred_train))
12 print(classification_report(Y_test, y_pred_test))

```

Листинг 13 – Алгоритм Decision Tree с подобранными гиперпараметрами методом *RandomizedSearchCV* на 3 000 000 данных

```

1 dtree = DecisionTreeClassifier(criterion='entropy',
2                               max_depth=25,
3                               max_features='log2',
4                               min_samples_leaf=10,
5                               min_samples_split=10,
6                               random_state=42)
7 dtree.fit(X_train, Y_train)
8 dtree.score(X_train, Y_train), dtree.score(X_test, Y_test)
9 y_pred_train = dtree.predict(X_train)
10 y_pred_test = dtree.predict(X_test)
11 print(classification_report(Y_train, y_pred_train))
12 print(classification_report(Y_test, y_pred_test))

```

Листинг 14 – Алгоритм Random Forest с подобранными гиперпараметрами методом *GridSearchCV* на 3 000 000 данных

```
1 rfc = RandomForestClassifier(max_depth=20,
2                               min_samples_leaf=10,
3                               min_samples_split=30,
4                               n_estimators=60,
5                               random_state=42)
6 rfc.fit(X_train, Y_train)
7 rfc.score(X_train, Y_train), rfc.score(X_test, Y_test)
8 y_pred_train = rfc.predict(X_train)
9 y_pred_test = rfc.predict(X_test)
10 print(classification_report(Y_train, y_pred_train))
11 print(classification_report(Y_test, y_pred_test))
```

Листинг 15 – Алгоритм Random Forest с подобранными гиперпараметрами методом *RandomizedSearchCV* на 3 000 000 данных

```
1 rfc = RandomForestClassifier(criterion='entropy',
2                               max_depth=30,
3                               min_samples_leaf=10,
4                               min_samples_split=10,
5                               max_features='log2',
6                               n_estimators=40,
7                               random_state=42)
8 rfc.fit(X_train, Y_train)
9 rfc.score(X_train, Y_train), rfc.score(X_test, Y_test)
10 y_pred_train = rfc.predict(X_train)
11 y_pred_test = rfc.predict(X_test)
12 print(classification_report(Y_train, y_pred_train))
13 print(classification_report(Y_test, y_pred_test))
```